高维岭回归正则扫描的多随机种子复验

A1 第 1 项：理论风险、测试误差与最优点稳定性

高维统计课程项目 2026 年 10 月 22 日

摘要

针对 BinaryTree 与 Exponential 协方差谱模型，在实际维数样本比 $\gamma = p/n = 1$ 下，分别以三个独立随机种子复验岭回归正则扫描。每组进行 500 次重复、每次使用 100 个测试点，统一扫描 62 个正则参数。观测最优参数相对理论最优值 $\lambda^* = 1$ 的最大偏离为 6.37%；合并种子后，两模型的观测最优点均为 1。精确条件风险揭示小幅有限样本近似差异，合并 Exponential 的测试风险也存在可见偏离。本文保留这些差异并分析其来源；全部汇总均已由逐重复原始数据独立复算。

1 实验设计与主要结果

本次对应周报 [2] “下周期可验收目标” 第 1 项。BinaryTree 沿用深度 $d = 4$ 的作者代码谱，取 $n = p = 2^4 - 1 = 15$；Exponential 使用率参数为 1 的中点分位谱，取 $n = p = 20$，不再强制归一化谱均值。两模型均设 $\alpha^2 = 1$、噪声方差为 1，每组重复数 $B = 500$，测试样本数 $m = 100$。公共正则网格为

$$\mathcal{L} = \left\{ \left(0.1 + \frac{j}{60}(\sqrt{10} - 0.1) \right)^2 : j = 0, \dots, 60 \right\} \cup \{1\}, \qquad |\mathcal{L}| = 62. \tag{1.1}$$

三个主种子记为 S1 = 2026102201、S2 = 2026102202、S3 = 2026102203。各模型以主种子和模型编号共同构造独立随机流；同次重复内所有 λ 共享训练与测试数据。共完成 6 组、3,000 次独立重复，保存 186,000 行逐重复与网格点记录。

表 1 理论最优点 $\lambda^* = 1$ 处的六组风险及观测最优参数

模型	种子	$\overline{T}(1) \pm \widehat{\mathrm{SE}}_T(1)$	R_1^{DE}	$\overline{T}(1) - R_1^{\mathrm{DE}}$	$\widehat{\lambda}$
BinaryTree	S1	1.51817 ± 0.01362	1.53135	−0.01318	1.03772
BinaryTree	S2	1.52268 ± 0.01504	1.53135	−0.00868	1.00000
BinaryTree	S3	1.52159 ± 0.01379	1.53135	−0.00976	1.00000
Exponential	S1	1.49829 ± 0.01340	1.48903	+0.00927	1.03772
Exponential	S2	1.51249 ± 0.01355	1.48903	+0.02346	0.93634
Exponential	S3	1.50987 ± 0.01309	1.48903	+0.02084	1.03772

注：风险均含不可约噪声；R_λ^{DE} 为有限总体谱确定性等价，$\overline{T}$ 为测试 MSE 的重复均值，$\widehat{\mathrm{SE}}_T$ 为该均值的标准误。$\widehat{\lambda}$ 为全网格测试均值的最小点，定义见式(3.7)。

各组 $\widehat{\lambda} \in \{0.93633750, 1, 1.03771566\}$，合并每模型 1,500 次重复后，两模型的最小点均为 1。该结果支持本次配置下最优区域的稳定性；风险数值的有限样本偏离另见第5节。

2 模型、风险口径与标准误

2.1 岭回归与三个风险量

每次重复 r 独立生成

$$X_r = Z_r\Sigma^{1/2}, \qquad y_r = X_r w_r + \varepsilon_r, \qquad w_r \sim N\left(0, \frac{\alpha^2}{p} I_p\right), \quad \varepsilon_r \sim N(0, I_n), \tag{2.1}$$

其中 Z_r 的元素独立服从 $N(0,1)$，且 Z_r, w_r, ε_r 相互独立。训练和测试响应共享本次真实系数 w_r；测试特征与噪声独立于训练数据。令 $S_r = X_r^{\mathsf{T}} X_r/n$，采用无截距岭估计

$$\widehat{w}_{r,\lambda} = \arg\min_{b\in\mathbb{R}^p} \left\{ \frac{1}{n} \|y_r - X_r b\|_2^2 + \lambda \|b\|_2^2 \right\}, \tag{2.2}$$

$$= A_{r,\lambda} \frac{X_r^{\mathsf{T}} y_r}{n}, \qquad A_{r,\lambda} = (S_r + \lambda I_p)^{-1}. \tag{2.3}$$

因此，未按 n 归一化的残差平方和对应惩罚系数 $n\lambda$。为区分理论近似与有限样本模拟，定义

$$T_r(\lambda) = \frac{1}{m} \sum_{i=1}^{m} \left[y_{ri}^{\text{test}} - (x_{ri}^{\text{test}})^{\mathsf{T}} \widehat{w}_{r,\lambda} \right]^2, \tag{2.4}$$

$$P_r(\lambda) = 1 + (\widehat{w}_{r,\lambda} - w_r)^{\mathsf{T}} \Sigma (\widehat{w}_{r,\lambda} - w_r), \tag{2.5}$$

$$C_r(\lambda) = \mathbb{E}[P_r(\lambda) \mid X_r]. \tag{2.6}$$

T_r 为有限测试集 MSE，P_r 为实际拟合模型的总体预测风险；C_r 进一步平均真实系数与训练噪声的随机性，是给定 X_r 的精确条件风险。由 [1] 第 2 节的风险分解，有

$$C_r(\lambda) = 1 + \frac{\alpha^2\lambda^2}{p} \operatorname{tr}(\Sigma A_{r,\lambda}^2) + \frac{1}{n} \operatorname{tr}(\Sigma A_{r,\lambda} S_r A_{r,\lambda}). \tag{2.7}$$

2.2 重复均值及其标准误

对预先指定的 λ，定义

$$\overline{T}(\lambda) = \frac{1}{B} \sum_{r=1}^{B} T_r(\lambda), \tag{2.8}$$

$$\widehat{\mathrm{SE}}_T(\lambda) = \left\{ \frac{1}{B(B-1)} \sum_{r=1}^{B} [T_r(\lambda) - \overline{T}(\lambda)]^2 \right\}^{1/2}. \tag{2.9}$$

标准误以 B 次独立重复为单位。同次重复内的网格点彼此相关，不能当作额外独立重复。$\overline{P}$、$\overline{C}$ 及其标准误同理定义。配对差 $T_r - C_r$ 使用差值自身的样本标准差计算标准误。

3 理论曲线及最优参数

3.1 有限总体谱的确定性等价

设总体协方差的特征值为 $t_1, \dots, t_p$，记 $H_p = p^{-1} \sum_{j=1}^{p} \delta_{t_j}$。本文将有限总体谱 H_p 代入一般协方差风险公式 [1]，得到确定性等价 R_λ^{DE}。负实轴上的伴随 Stieltjes 变换 $v_\lambda = v(-\lambda) > 0$ 满足

$$\lambda v_\lambda + \gamma \int \frac{t v_\lambda}{1 + t v_\lambda} \, \mathrm{d}H_p(t) = 1, \qquad 0 < v_\lambda < \lambda^{-1}. \tag{3.1}$$

令

$$d_\lambda = \int \frac{t^2}{(1 + t v_\lambda)^2} \, \mathrm{d}H_p(t), \qquad j_\lambda = \int \frac{t}{(1 + t v_\lambda)^2} \, \mathrm{d}H_p(t), \tag{3.2}$$

$$D_\lambda = 1 - \gamma v_\lambda^2 d_\lambda > 0. \tag{3.3}$$

数值实现使用避免相近数相减的非负分量形式：

$$R_\lambda^{\mathrm{DE}} = 1 + \underbrace{\frac{\alpha^2 j_\lambda}{D_\lambda}}_{\text{收缩偏差贡献}} + \underbrace{\frac{\gamma v_\lambda^2 d_\lambda}{D_\lambda}}_{\text{训练噪声方差贡献}}. \tag{3.4}$$

它是有限样本风险的理论近似，并不等于精确的 $\mathbb{E}_X[C_r(\lambda)]$。本次 $n = p = 15$ 或 20 的复验只评价固定配置的数值表现，不据此作任意样本规模或任意增维谱序列的无偏保证。

3.2 一般协方差下的条件风险最优点

由式(2.7)，并利用 $A_{r,\lambda}$ 与 S_r 可交换，对 λ 求导得

$$C_r'(\lambda) = 2 \left(\frac{\alpha^2 \lambda}{p} - \frac{1}{n} \right) \mathrm{tr}\left[\Sigma S_r (S_r + \lambda I_p)^{-3} \right]. \tag{3.5}$$

本次两种 Σ 均正定；若 S_r 存在非零方向，则上式迹项严格为正。因此，每个固定训练设计的唯一最优参数为

$$\lambda^* = \frac{p}{n\alpha^2} = \frac{\gamma}{\alpha^2} = 1. \tag{3.6}$$

六组保存的条件风险均值也都在 $\lambda = 1$ 取得网格最小值。有限测试均值的观测最优参数定义为

$$\widehat{\lambda} = \arg\min_{\lambda \in \mathcal{L}} \overline{T}(\lambda). \tag{3.7}$$

随种子变化的是式(3.7)，而非式(3.6)。两者需要分别解释：前者包含模拟波动和网格选择，后者是本模型的条件风险结论。

4 风险曲线的多种子稳定性

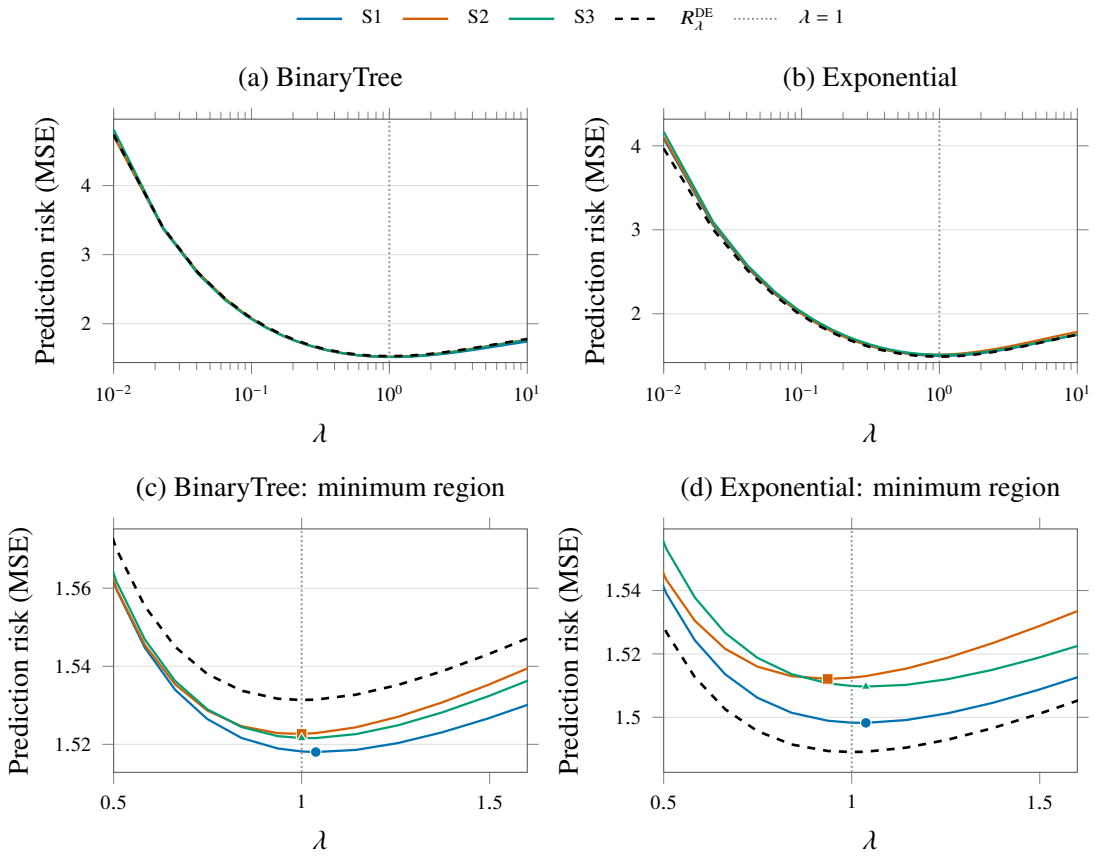


图 1 两模型的测试风险正则扫描。上排为完整范围，下排放大最优区域。彩色实线为三个种子的 $\overline{T}(\lambda)$，黑色虚线为 R_λ^{DE}，竖直点线为 $\lambda = 1$，标记点为各组 $\widehat{\lambda}$。本图仅绘重复均值曲线，不绘置信带。

图1中，三个种子均显示风险随正则强度先下降、后上升的形状，且低谷位于 $\lambda = 1$ 附近。BinaryTree 三个种子的观测最优参数分别为 1.03771566、1、1；Exponential 分别为 1.03771566、0.93633750、1.03771566。不同种子支持相同的最优区域结论，合并后两模型均取 $\widehat{\lambda} = 1$。

从 $\lambda = 1$ 改选每组观测最小点，测试 MSE 均值最多下降 3.8052×10^{-4}；低谷的平坦性解释了为何小幅均值波动也会移动观测最优参数。风险值在纵向的差异仍应与理论近似差异区分，不能仅凭曲线形状相似而忽略。

5 理论差值的分解与偏离分析

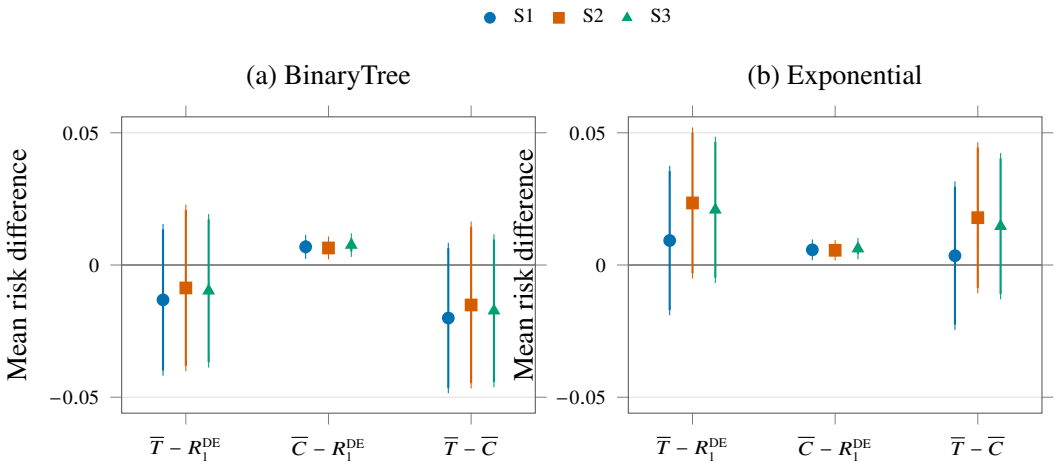


图 2 固定 $\lambda = 1$ 的风险差分量。各点为独立重复的均值差，误差棒为该分量的均值 $\pm 1.96\widehat{\mathrm{SE}}$；$\overline{T} - \overline{C}$ 使用同次重复配对差的标准误。所有区间均为点态近似区间。

表 2 合并三个种子后在 $\lambda = 1$ 处的风险分解（每模型 $B = 1{,}500$）

模型	$\overline{T} \pm \widehat{\mathrm{SE}}_T$	$\overline{T} - R_1^{\mathrm{DE}}$	$\overline{T} - \overline{C}$	$\overline{C} - R_1^{\mathrm{DE}}$
BinaryTree	1.52081 ± 0.00817	-0.01054	-0.01749	$+0.00695$
Exponential	1.50689 ± 0.00770	$+0.01786$	$+0.01203$	$+0.00583$

六个单种子在 $\lambda = 1$ 处均有 $|\overline{T} - R_1^{\mathrm{DE}}|/\widehat{\mathrm{SE}}_T \le 1.732$。但合并 Exponential 的差为 $+0.01785721$，标准误为 0.00770400，描述性比例为 2.3179；其普通点态区间 $[1.49178617, 1.52198587]$ 不含理论值 1.48902882。

合并条件风险相对理论的差分别为 0.00694870（BinaryTree，$\widehat{\mathrm{SE}}_C = 0.00072092$）和 0.00582561（Exponential，$\widehat{\mathrm{SE}}_C = 0.00056242$），约占各自理论风险的 0.45% 和 0.39%。它们提示小幅有限样本近似差异，且仍含训练设计的抽样误差。风险差可进一步严格分解为

$$\overline{T} - R_\lambda^{\mathrm{DE}} = (\overline{T} - \overline{P}) + (\overline{P} - \overline{C}) + (\overline{C} - R_\lambda^{\mathrm{DE}}), \tag{5.1}$$

其中前两项分别为有限测试样本波动、系数与训练噪声抽样波动；最后一项满足

$$\overline{C} - R_\lambda^{\mathrm{DE}} = (\overline{C} - \mathbb{E}_X C_r) + (\mathbb{E}_X C_r - R_\lambda^{\mathrm{DE}}). \tag{5.2}$$

故不能把测试与理论的全部差异归因于测试集太小，也不能将 $\overline{C} - R_\lambda^{\mathrm{DE}}$ 视为没有抽样误差的偏差真值。

6 观测最优点的漂移及其风险代价

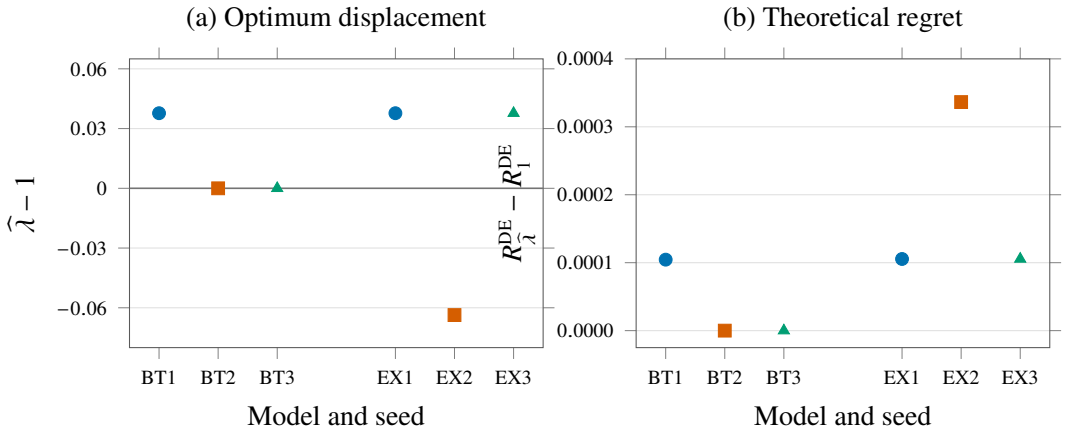


图 3 观测最优参数的位移与理论风险增量。BT1–BT3 表示 BinaryTree 的 S1–S3；EX1–EX3 表示 Exponential 的 S1–S3。左图为 $\widehat{\lambda} - 1$，右图为 $R^{\mathrm{DE}}_{\widehat{\lambda}} - R^{\mathrm{DE}}_{1}$。每点对应一次完整种子组的网格最小值，不表示最优点的置信区间。

定义相对位移和确定性理论风险增量

$$\delta_\lambda = \frac{|\widehat{\lambda} - \lambda^*|}{\lambda^*}, \qquad \mathcal{E}_{\mathrm{DE}} = R^{\mathrm{DE}}_{\widehat{\lambda}} - R^{\mathrm{DE}}_{\lambda^*}. \tag{6.1}$$

六组最大相对位移为 6.3663%，最大理论风险增量为 3.36398×10^{-4}，低于 0.000337。这表明观测最优点的位移对应很小的理论风险代价，与图1中的平坦低谷一致。

6.1 关于选择偏差和区间的解释

由于 $\widehat{\lambda}$ 与 $\overline{T}(\widehat{\lambda})$ 由同一批测试均值选出，观测最小风险具有向下的选择偏差。它相对 $\overline{T}(1)$ 的小幅下降只是描述性比较，不能解释为正式的性能优胜；若需作选参后的统计推断，应使用独立验证数据或适当的选择校正。同样，固定 λ 的均值 $\pm 1.96\widehat{\mathrm{SE}}$ 只是近似点态区间，既不是整条曲线的同时置信带，也不是选择后风险的有效置信区间。

6.2 可验收结论

在本次固定小样本配置和公共网格下，三个种子支持相同的风险曲线形状与最优区域；每模型合并后，测试均值最优点均为 $\lambda = 1$。与此同时，风险值存在小幅有限样本近似差异，合并 Exponential 的偏离尤其需要保留。因此，最优区域的稳定性和风险近似的数值精度是两个应分别陈述的结论。

7 复算核验与交付对应

7.1 已经执行的独立核验

独立核验脚本直接从原始逐重复 CSV 重算全部汇总，未调用实验脚本的汇总函数：

- 核对 186,000 个唯一的种子、模型、重复与网格组合，无缺失和重复；每组均有 500 次重复和 62 个正则点。
- 重算 496 行扫描汇总与 8 行最优点汇总（均含合并结果），最大绝对差为 1.64×10^{-14}。
- 重放 6 组首个重复的全部网格，与 372 次直接矩阵求解比较，精确条件风险最大绝对差为 2.32×10^{-13}。
- 原有总体谱、Stieltjes 方程、一般协方差条件风险及零空间核验均通过；源代码与数据的 SHA256 校验一致。

另有独立审查使用标准库统计函数复算六组结果，数值一致。算术核验确认实现与数据完整性，不替代对选择偏差或模型近似误差的统计解释。

7.2 交付文件与验收标准

表 3 验收要求与可核验产物的对应

验收要求	对应文件或正文位置
两模型各三个独立种子	`config.json`；`data/raw_repetitions.csv`
统一实际 γ、网格、重复和测试规模	`config.json`；`data/lambda_grid.csv`；式(1.1)
MSE、SE、理论差值与观测最优参数	表1；`data/optima_summary.csv`
所有数值可从原始记录复算	`verify_results.py`；`verification.json`
跨种子稳定性及明显偏离的分析	第4–6节；`methods_review.md`
可编辑的规范数学排版	本报告的独立 LaTeX 源文件，含全部内联绘图坐标

实验实际运行环境为 Python 3.12.14、NumPy 2.3.5。本次数学排版修订保留同一组已核验数据，不重新抽样。交付的源文件使用 `XeLaTeX` 连续编译两遍即可生成 PDF，公式由数学环境排版，图形由 PGFPlots 原生绘制，编译时无需外部 CSV 或图片。

参考文献

[1] Dobriban E, Wager S. High-dimensional asymptotics of prediction: Ridge regression and classification[J]. The Annals of Statistics, 2018, 46(1): 247–279. 第 2 节、定理 2.1 及其证明.

[2] 第 3 组. 高维统计课程项目周报 [R]. 报告周期：2026 年 9 月 18 日至 10 月 8 日. 第 4 页，“下周期可验收目标” 第 1 项.

[3] A1 项目实现. `A1_ridge_reproduction.py`；本次扩展：`run_experiment.py`、`verify_results.py`. 运行配置、完整数值与独立核验记录见随附材料.