# 高维岭回归预测风险

## A1：理论分析与数值复现

基于 Dobriban 与 Wager（2018）第 2 节

2026 年 10 月 4 日

**摘要**

本文基于 Dobriban 与 Wager（2018）第 2 节，研究维数与样本量同阶增长时岭回归的预测风险。通过偏差与方差分解及样本协方差的谱极限，给出一般协方差下的渐近风险，并在单位协方差情形推导可计算公式、最优正则参数与强信号学习区间。实验框架包括单位协方差对照及原文 BinaryTree、Exponential 谱模型，比较理论风险、有限样本条件风险和独立测试误差，考察正则强度与维数样本比的影响。

## 1 Introduction

当特征维数 $p$ 与训练样本量 $n$ 同阶增长时，经典低维回归中以总体协方差近似样本协方差的思路不再充分：即使特征独立且具有单位方差，样本协方差仍具有非平凡的谱分布，小特征值会放大训练噪声，而 $p > n$ 时还存在无法由训练数据识别的方向。岭回归通过正则化控制噪声放大，同时引入信号收缩偏差，其预测表现因而取决于维数样本比 $\gamma = p/n$、正则强度 $\lambda$、信号强度与总体协方差。Dobriban 与 Wager[1] 利用随机矩阵理论刻画了这一风险在高维极限下的确定性表达式，为分析最优正则化与不同学习区间提供了依据。本文围绕 A1 的高维岭回归预测问题，先集中推导风险公式及其参数含义，再以单位协方差为对照，复现原文 BinaryTree 与 Exponential 模型的实验设定，检验理论对有限样本预测误差的解释能力。

## 2 理论基础

### 2.1 模型设定与预测风险

考虑随机设计线性模型

$$Y = Xw + \varepsilon, \qquad X \in \mathbb{R}^{n\times p}, \qquad \mathbb{E}[x_i] = 0, \quad \mathrm{Cov}(x_i) = \Sigma. \tag{1}$$

系数与训练特征独立，满足随机系数假设

$$\mathbb{E}[w] = 0, \qquad \mathrm{Cov}(w) = \frac{\alpha^2}{p} I_p, \qquad \mathbb{E}[\|w\|_2^2] = \alpha^2. \tag{2}$$

训练噪声独立于特征和系数，均值为零、方差为 1。参数 $\alpha^2$ 表示系数总能量；平均信号方差为 $\alpha^2 \operatorname{tr}(\Sigma)/p$，在 $\Sigma = I_p$ 时等于 $\alpha^2$。这种随维数缩放的系数方差使不同 $p$ 的模型具有可比的信号强度。岭回归定义为

$$\widehat{w}_\lambda = \operatorname*{arg\,min}_{b \in \mathbb{R}^p} \left\{ \frac{1}{n} \|Y - Xb\|_2^2 + \lambda \|b\|_2^2 \right\}, \qquad \lambda > 0, \tag{3}$$

$$\widehat{w}_\lambda = (X^\top X + n\lambda I_p)^{-1} X^\top Y. \tag{4}$$

因此，若实现采用未除以 $n$ 的残差平方和，其惩罚系数应为 $n\lambda$。模型均值为零，不另设截距。

独立测试点 $(x_0, y_0)$ 与训练数据共享真实系数 $w$。固定训练特征矩阵后，论文研究的总预测风险为

$$r_\lambda(X) = \mathbb{E}\left[ (y_0 - x_0^\top \widehat{w}_\lambda)^2 \middle| X \right], \tag{5}$$

其中期望平均了系数、训练噪声及测试点的随机性。令 $S = X^\top X/n$、$A = (S + \lambda I_p)^{-1}$，估计误差满足

$$\widehat{w}_\lambda - w = -\lambda A w + \frac{1}{n} A X^\top \varepsilon. \tag{6}$$

两项交叉乘积的期望为零，从而得到偏差与方差分解

$$r_\lambda(X) = 1 + B_\lambda(X) + V_\lambda(X), \tag{7}$$

$$B_\lambda(X) = \frac{\alpha^2 \lambda^2}{p} \operatorname{tr}(\Sigma A^2), \qquad V_\lambda(X) = \frac{1}{n} \operatorname{tr}(\Sigma A S A). \tag{8}$$

常数 1 是不可约测试噪声；$B_\lambda$ 为信号收缩造成的误差，$V_\lambda$ 为训练噪声传递至预测器的误差。利用 $ASA = A - \lambda A^2$，记实际维数样本比 $\gamma_p = p/n$，可将风险写成

$$r_\lambda(X) = 1 + \frac{\gamma_p}{p} \operatorname{tr}(\Sigma A) + \frac{\lambda(\lambda\alpha^2 - \gamma_p)}{p} \operatorname{tr}(\Sigma A^2). \tag{9}$$

总风险减去 1 为超额预测风险，它仅在 $\Sigma = I_p$ 时等于参数估计的均方误差。单位协方差下，若 $s_1, \ldots, s_p$ 为 $S$ 的全部特征值，则

$$r_\lambda(X) = 1 + \frac{\alpha^2}{p} \sum_{i=1}^{p} \frac{\lambda^2}{(s_i + \lambda)^2} + \frac{1}{n} \sum_{i=1}^{p} \frac{s_i}{(s_i + \lambda)^2}. \tag{10}$$

高斯设计中 $p > n$ 时几乎必然存在 $p - n$ 个零特征值，其合计偏差为 $\alpha^2(p - n)/p$；计算风险时必须保留这一不可识别部分。

一般协方差下，令 $S = Q \operatorname{diag}(s_1, \ldots, s_p) Q^\top$，以 $q_i$ 表示 $Q$ 的第 $i$ 列，定义权重 $a_i = q_i^\top \Sigma q_i$。精确条件风险为

$$r_\lambda(X) = 1 + \frac{\alpha^2}{p} \sum_{i=1}^{p} a_i \frac{\lambda^2}{(s_i + \lambda)^2} + \frac{1}{n} \sum_{i=1}^{p} a_i \frac{s_i}{(s_i + \lambda)^2}. \tag{11}$$

若采用 $XX^{\mathsf{T}}/n$ 的较小矩阵计算正谱，其对应方向为 $q_i = X^{\mathsf{T}}u_i/\sqrt{ns_i}$。未包含的零空间偏差应补为

$$B_0 = \frac{\alpha^2}{p}\left[\operatorname{tr}(\Sigma) - \sum_{s_i>0} a_i\right]. \tag{12}$$

拟合后单个模型的总体预测误差则为 $1 + (\widehat{w}_\lambda - w)^{\mathsf{T}}\Sigma(\widehat{w}_\lambda - w)$。两种量都必须使用协方差权重，不能沿用单位协方差下的系数误差平方范数。

### 2.2 高维极限与可计算风险公式

高维渐近设定为 $n, p \to \infty$ 且 $p/n \to \gamma > 0$。论文令 $X = Z\Sigma^{1/2}$，其中 $Z$ 的元素独立同分布、均值为零、方差为 1，并要求其十二阶矩和 $\Sigma$ 的算子范数一致有界；总体协方差的经验谱分布收敛到 $H$[1, 定理 2.1]。总体谱 $H$ 与样本协方差的极限谱 $F$ 不同：$\Sigma = I_p$ 时 $H = \delta_1$，而 $F$ 为依赖 $\gamma$ 的 Marchenko–Pastur 分布。引入样本谱的 Stieltjes 变换及其伴随变换

$$m(z) = \int \frac{1}{t - z}\,\mathrm{d}F(t), \qquad v(z) = \gamma m(z) + \frac{\gamma - 1}{z}. \tag{13}$$

在 $z = -\lambda$ 处，$m(-\lambda)$ 和 $m'(-\lambda)$ 分别对应逆矩阵及其平方的平均迹。一般协方差下，定理 2.1 给出几乎必然极限

$$\begin{aligned} r_\lambda(X) &\longrightarrow R_\lambda(H, \alpha^2, \gamma), \\ R_\lambda(H, \alpha^2, \gamma) &= \frac{1}{\lambda v(-\lambda)}\left\{1 + \left(\frac{\lambda\alpha^2}{\gamma} - 1\right)\left[1 - \frac{\lambda v'(-\lambda)}{v(-\lambda)}\right]\right\}. \end{aligned} \tag{14}$$

该结论针对固定的 $\lambda > 0$；有限样本风险与极限风险不必精确相等。最优正则参数及相应极限风险为

$$\lambda^* = \frac{\gamma}{\alpha^2}, \qquad R^* = \frac{1}{\lambda^* v(-\lambda^*)}. \tag{15}$$

这里的导数以 $z$ 为变量，因此 $\mathrm{d}m(-\lambda)/\mathrm{d}\lambda = -m'(-\lambda)$。

数值计算一般协方差风险时，令 $H_p = p^{-1}\sum_{i=1}^{p}\delta_{t_i}$ 为有限总体协方差的经验谱。其伴随变换在负实轴上满足

$$\lambda v + \gamma\frac{1}{p}\sum_{i=1}^{p}\frac{t_i v}{1 + t_i v} = 1, \qquad v = v(-\lambda) > 0. \tag{16}$$

左侧关于 $v$ 严格递增，因此可在 $(0, 1/\lambda)$ 上二分求根。记

$$D(v) = \frac{1}{p}\sum_i \frac{t_i^2}{(1 + t_i v)^2}, \qquad J(v) = \frac{1}{p}\sum_i \frac{t_i}{(1 + t_i v)^2}, \qquad C(v) = 1 - \gamma v^2 D(v), \tag{17}$$

则 $v'(-\lambda) = v^2/C(v)$，并有等价的非负分量表达式

$$B = \frac{\alpha^2 J(v)}{C(v)}, \qquad V = \frac{\gamma v^2 D(v)}{C(v)}, \qquad R_\lambda = 1 + B + V. \tag{18}$$

该写法避免风险公式中的相减损失。当 $H_p = \delta_1$ 时应还原单位协方差闭式结果。以 $H_p$ 代入极限公式是作者代码使用的有限总体谱确定性等价口径 [2]，与式 (11) 的有限样本精确条件风险有不同含义。

两种原文谱模型按公开代码定义。BinaryTree 的深度为 $d$、维数为 $p = 2^d - 1$，原始特征值 $2^j$ 的重数为 $2^{d-j}$，$j = 1, \dots, d$，再统一除以平均特征值，使 $\operatorname{tr}(\Sigma)/p = 1$。Exponential 的特征值采用指数率 $r > 0$ 的中点分位数：

$$t_i = -\frac{1}{r} \log\left(\frac{i - 1/2}{p}\right), \qquad i = 1, \dots, p. \tag{19}$$

此处的指数分布用于协方差特征值，BinaryTree 指二叉树谱结构；训练特征仍按 $X = Z\Sigma^{1/2}$ 由高斯变量生成。按作者实现，Exponential 不额外归一化有限维谱的均值，因此其平均信号方差为 $\alpha^2 p^{-1} \sum_i t_i$。

在本次复现的 $\Sigma = I_p$ 情形，记 $b = 1 - \gamma + \lambda$、$h = m(-\lambda)$ 和 $q = m'(-\lambda)$，Marchenko–Pastur 变换可显式写为 [1, 式（7）]

$$h = \frac{-b + \sqrt{b^2 + 4\gamma\lambda}}{2\gamma\lambda} = \frac{2}{b + \sqrt{b^2 + 4\gamma\lambda}}, \tag{20}$$

$$q = \frac{\gamma h^2 + h}{2\gamma\lambda h + b}. \tag{21}$$

第二式由 $\gamma\lambda h^2 + bh - 1 = 0$ 隐式求导得到，避免数值差分。于是渐近风险及其分解为

$$R_\lambda(\alpha^2, \gamma) = 1 + \gamma h + \lambda(\lambda\alpha^2 - \gamma)q, \tag{22}$$

$$B = \alpha^2\lambda^2 q, \qquad V = \gamma(h - \lambda q), \qquad R_\lambda = 1 + B + V. \tag{23}$$

计算 $h$ 时，$b \geq 0$ 使用式 (20) 的第二种形式，$b < 0$ 使用第一种形式，可以减少相消误差。最优点处 $q$ 的系数消失；令 $c = (\gamma - 1)\alpha^2/\gamma$，得到

$$R^*(\alpha^2, \gamma) = \frac{1 + c + \sqrt{(1 - c)^2 + 4\alpha^2}}{2}. \tag{24}$$

### 2.3 正则化、维数样本比与学习区间

正则化降低训练噪声引起的方差，同时增加信号收缩偏差。对单位协方差下的有限样本条件风险求导，有

$$\frac{\mathrm{d}r_\lambda(X)}{\mathrm{d}\lambda} = 2\left(\frac{\alpha^2\lambda}{p} - \frac{1}{n}\right)\sum_{i=1}^{p} \frac{s_i}{(s_i + \lambda)^3}. \tag{25}$$

只要存在正特征值，风险即在 $\lambda_p^* = p/(n\alpha^2)$ 左侧下降、右侧上升。因此该参数不仅是渐近最优选择，也是精确条件风险的最小点；独立测试 MSE 的最低点则会受到有限重复和离散网格的影响。维数样本比越大，所需正则越强；信号越强，最优收缩越弱。对一般协方差，式 (11) 求导后仅需在求和项中加入非负权重 $a_i$，最优参数仍为 $p/(n\alpha^2)$。协方差谱改变风险的水平与形状，但不改变本文随机系数假设下的这一最优正则关系。

在 $\alpha^2$ 固定时，单位协方差风险满足以下边界：

$$\lim_{\lambda \to \infty} R_\lambda = 1 + \alpha^2, \tag{26}$$

$$\lim_{\lambda \downarrow 0} R_\lambda = \begin{cases} (1 - \gamma)^{-1}, & \gamma < 1, \\ \dfrac{\gamma}{\gamma - 1} + \alpha^2\left(1 - \dfrac{1}{\gamma}\right), & \gamma > 1. \end{cases} \tag{27}$$

强正则的极限是零预测器；弱正则的两个极限分别对应普通最小二乘和最小范数解。$\gamma = 1$ 时，$\lambda \downarrow 0$ 导致风险发散。这些结论是在先取高维极限后得到的；固定正 $\lambda$ 会缓和插值阈值附近的噪声放大。固定 $\lambda$ 的维数扫描可能呈现非单调风险，而逐个 $\gamma$ 最优调参的 $R^*$ 随 $\gamma$ 增加而上升，并趋于 $1 + \alpha^2$。由于系数分布随 $p$ 缩放，该比较描述的是固定总信号强度的模型族。

学习区间还取决于信号强度。弱信号 $\alpha^2 \to 0$ 时，$\lambda^* \to \infty$，$R^* \to 1$ 且 $R^* - 1 \sim \alpha^2$。强信号 $\alpha^2 \to \infty$ 时，按 $\lambda^* = \gamma/\alpha^2$ 调参后有

$$\gamma < 1: \qquad R^* \longrightarrow \frac{1}{1-\gamma}, \tag{28}$$

$$\gamma = 1: \qquad R^* = \frac{1+\sqrt{1+4\alpha^2}}{2} = \Theta(\alpha), \tag{29}$$

$$\gamma > 1: \qquad \frac{R^*}{\alpha^2} \longrightarrow 1 - \frac{1}{\gamma}, \quad R^* = \Theta(\alpha^2). \tag{30}$$

因此，以 $\alpha^2$ 为横轴的双对数图在强信号区呈现 0、1/2 和 1 三类渐近斜率。这是最优风险的强信号相变，与固定信号、固定正则的维数扫描具有不同含义。

一般协方差下，论文进一步给出最优预测风险 $R_P$ 与参数估计风险 $R_E$ 的关系 [1, 推论 2.4]：

$$1 - \frac{1}{R_P} = \gamma\left(1 - \frac{R_E}{\alpha^2}\right). \tag{31}$$

在 $\gamma = 1$ 时有 $R_E R_P = \alpha^2$。这体现了协方差结构对预测与系数恢复的不同作用；在单位协方差的同一模型中，超额预测风险仍等于参数估计风险。

# 3 实验复现

## 3.1 实验设置与评价指标

采用 Python 与 NumPy 实现单位协方差模型。每次重复独立生成 $X_{ij} \sim \mathcal{N}(0,1)$、$w \sim \mathcal{N}(0, (\alpha^2/p) I_p)$ 和 $\varepsilon \sim \mathcal{N}(0, I_n)$，构造 $Y = Xw + \varepsilon$ 并拟合岭回归；随后生成独立测试集，训练与测试共享同一个 $w$。基础实验采用 $n = 120$、$\alpha^2 = 1$，每组 100 次独立重复，每次测试集 $T = 2000$；随机种子为 20261004。正则扫描取 $\gamma \in \{0.5, 1, 2\}$、$\lambda \in [0.01, 10]$，采用对数网格并加入理论最优点；维数扫描取 $\lambda \in \{0.1, 1, 4\}$、$\gamma \in [0.25, 2.5]$。令 $p = \mathrm{round}(n\gamma)$，理论计算使用实际比值 $p/n$。评价指标为

$$\mathrm{MSE}_{\mathrm{test}} = \frac{1}{T}\sum_{j=1}^{T}\left(y_j^{\mathrm{test}} - (x_j^{\mathrm{test}})^{\top}\widehat{w}_\lambda\right)^2. \tag{32}$$

每组比较渐近风险 $R_\lambda$、由式 (10) 精确计算的条件风险 $r_\lambda(X)$，以及实际训练后的测试 MSE。重复均值的标准误为 $\mathrm{SE} = \mathrm{sd}(M_1, \ldots, M_K)/\sqrt{K}$，其中 $M_k$ 为第 $k$ 次重复的测试 MSE；图中误差线取均值加减 1.96 SE，表示近似点态 95% 区间。

### 3.2 正则化与维数变化的风险表现

表 1 比较理论最优点处的三种风险。条件风险均值与渐近预测接近，测试均值在重复误差范围内表现一致。图 1 进一步展示完整的正则路径。风险随 $\lambda$ 先下降后上升，最

表 1: 理论最优点处的预测风险比较；测试均值后给出标准误。

| $\gamma$ | $\lambda^*$ | 理论风险 | 条件风险均值 | 测试 MSE 均值 ± SE |
|---|---|---|---|---|
| 0.5 | 0.5 | 1.4142 | 1.4160 | 1.4175 ± 0.0080 |
| 1 | 1 | 1.6180 | 1.6184 | 1.6120 ± 0.0108 |
| 2 | 2 | 1.7808 | 1.7810 | 1.7775 ± 0.0096 |

低点位于 $\gamma/\alpha^2$ 附近；增大 $\gamma$ 后，最优点向更强正则方向移动。条件风险与理论曲线接近，有限测试 MSE 的最低点受到随机波动与网格分辨率影响。固定正则的维数扫描见

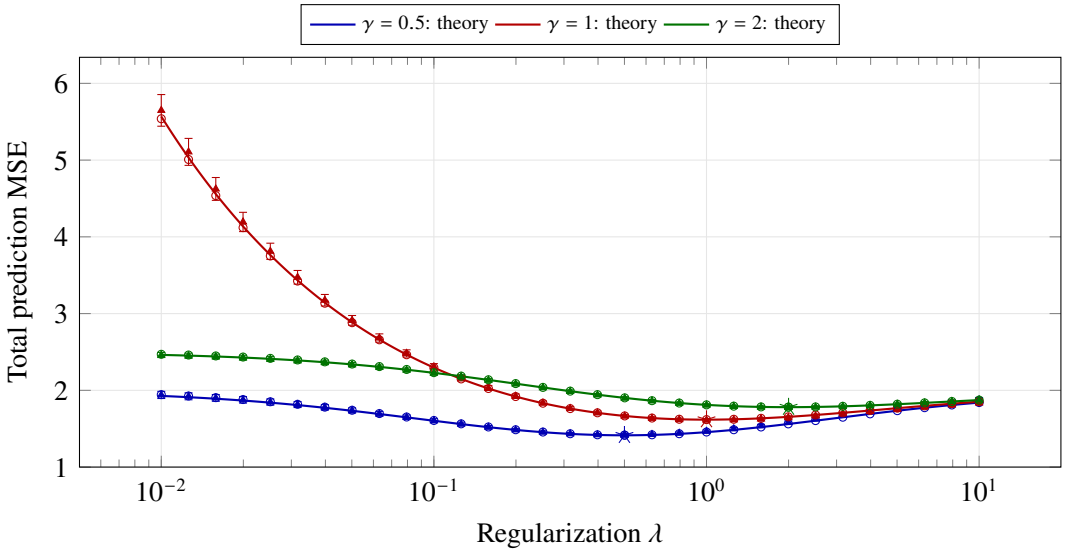



图 1: 固定 $\gamma$ 扫描 $\lambda$。实线为渐近风险，空心圆为条件风险均值，实心三角为独立测试 MSE 均值；误差线为均值的近似点态 95% 区间。星号标出理论最优点 $\lambda^* = \gamma/\alpha^2$。

图 2。较弱正则在插值阈值附近产生明显风险峰，峰值位置可以偏离 $\gamma = 1$；增强正则后，噪声放大得到缓和，曲线更平滑。该比较保持样本量、总信号强度和噪声方差一致，反映固定收缩强度对不同维数的适应程度。图 3 用式 (23) 解释上述现象：随着 $\lambda$ 增加，收缩偏差上升，训练噪声方差下降，总风险在两者平衡处达到最低点。不可约噪声贡献始终为 1。该图由解析公式计算，用于说明风险变化的机制。

### 3.3 强信号学习区间

为复现论文第 2.1 节的学习区间现象，取 $\gamma \in \{0.5, 0.9, 1, 1.1, 2\}$，在 $\alpha^2 \in [0.01, 10^4]$ 上扫描式 (24)，每个点均使用 $\lambda^* = \gamma/\alpha^2$。图 4 在强信号区呈现常数量级、$\alpha$ 量级和 $\alpha^2$ 量级三类增长，双对数斜率分别趋于 0、1/2 和 1，与式 (28)–(30) 一致。该图展示单位协方差下的理论现象。

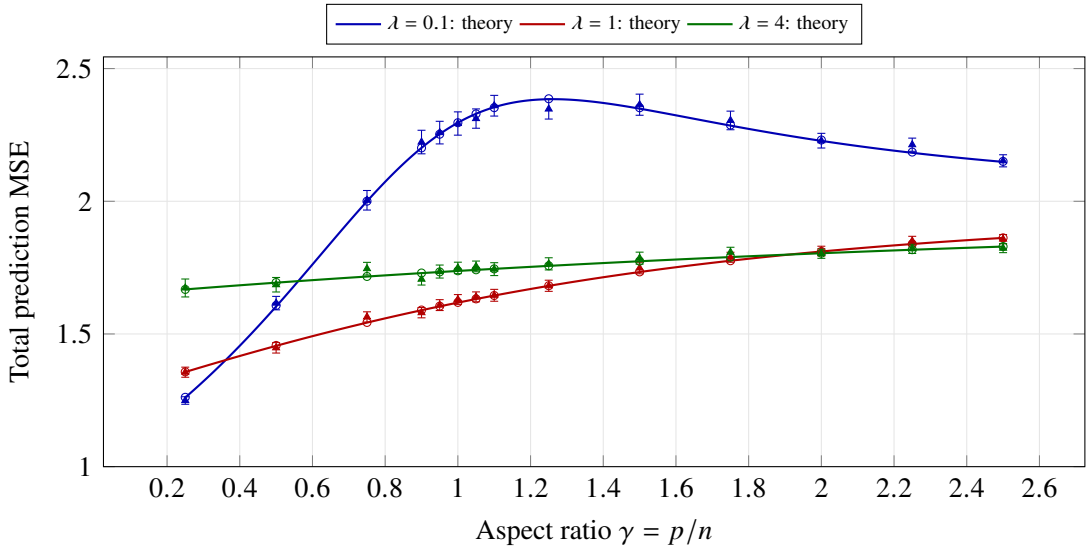



图 2: 固定 $\lambda$ 扫描 $\gamma$。实线为渐近风险，空心圆为条件风险均值，实心三角为独立测试 MSE 均值；误差线为均值的近似点态 95% 区间。

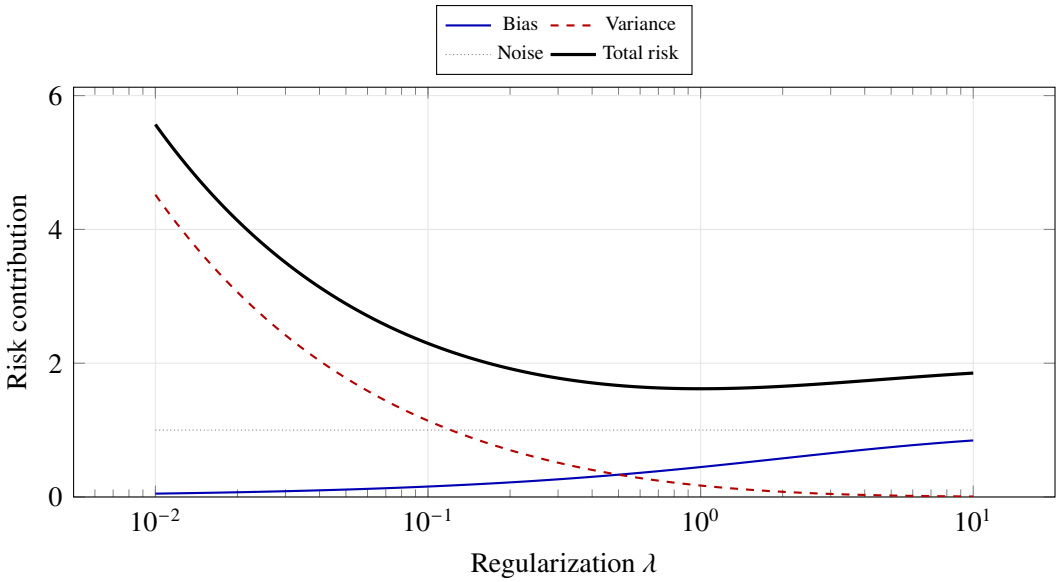



图 3: 偏差、方差与总风险的理论分解（$\Sigma = I_p$、$\gamma = 1$）。总风险为 $1 + B + V$；曲线由公式计算，不是新增模拟结果。

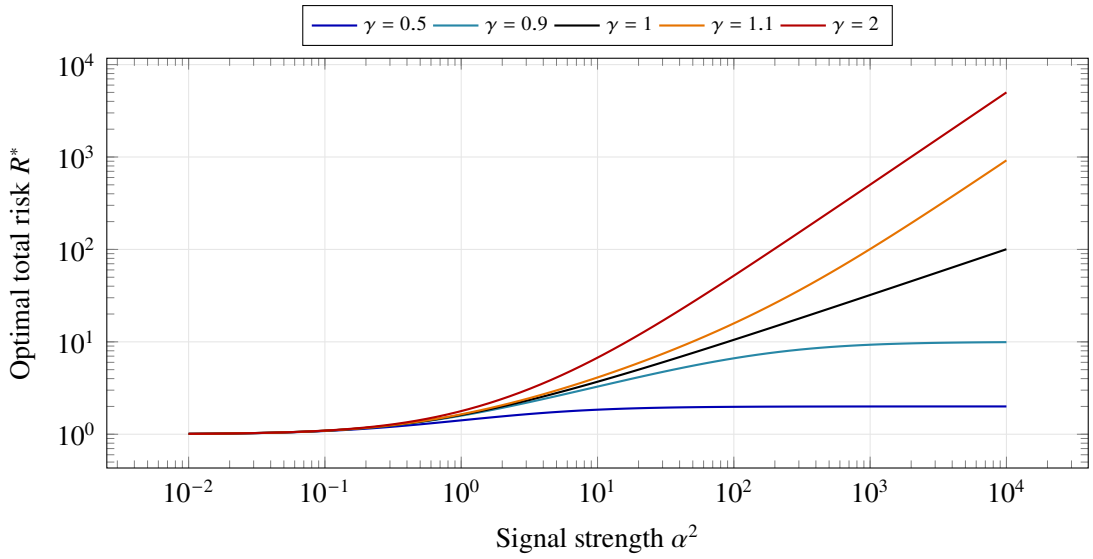



图 4: 单位协方差下的强信号学习区间：每个点均使用 $\lambda^* = \gamma/\alpha^2$。本图选择 $\gamma \in \{0.5, 0.9, 1, 1.1, 2\}$，展示原论文图 3 的理论现象，并非其全部参数设置的逐点重绘。

### 3.4 有限样本核验与讨论

在 $\gamma = 1$、$\lambda = 1/\alpha^2$ 处，取 $n = p \in \{120, 300, 600\}$ 并独立重复抽取训练特征。表 2 显示各样本量下的条件风险均值均接近理论极限；这里考察的是渐近近似，随机误差不要求逐次单调下降。直接线性方程求解与谱方法的最大系数差为 $1.25 \times 10^{-14}$，谱风险

表 2: 不同样本规模下的条件风险与高维极限。

| $n = p$ | 理论风险 | 条件风险均值 | 绝对差 |
|---|---|---|---|
| 120 | 1.618034 | 1.618721 | 0.000687 |
| 300 | 1.618034 | 1.618327 | 0.000293 |
| 600 | 1.618034 | 1.618113 | 0.000079 |

与迹风险的最大差为 $1.31 \times 10^{-13}$。固定训练特征后进行了 4000 次系数与训练噪声重复，平均模型总体风险与精确条件风险的最大标准化偏差为 1.50，通过程序核验。边界核验还包括无正则极限、零预测器风险、有限样本最优参数及过参数区的零特征值贡献。上述基础实验考察单位协方差，原文两种协方差模型的复现见下文。复现代码为 `A1_ridge_reproduction.py`，参数、原始数值和运行说明保存在同目录，四张图的坐标嵌入本文源文件。

### 3.5 原文协方差模型的实验复现

原文图 2 使用 BinaryTree 与 Exponential 两种总体协方差模型 [1, 2]。本文按作者公开代码构造其特征值，采用谱等价表示 $\Sigma = \mathrm{diag}(t_1, \ldots, t_p)$ 和 $X = Z\Sigma^{1/2}$。由于高斯系数分布及岭惩罚具有旋转不变性，该表示保留预测风险的分布；两种模型的训练和测试特征均为高斯变量，模型名称描述的是协方差谱。BinaryTree 取深度 $d = 4$，因此

$p = 2^d - 1 = 15$，按 $n = \lfloor p/\gamma_0 \rfloor$ 选择样本量；Exponential 固定 $n = 20$，按 $p = \lfloor n\gamma_0 \rfloor$ 选择维数，指数率为 1。$\gamma_0$ 是目标比值，所有理论和最优参数计算均使用实际 $\gamma = p/n$。两模型的正则扫描取 $\gamma_0 \in \{0.5, 1, 2\}$，信号强度 $\alpha^2 = 1$、噪声方差 1，每组独立重复 500 次，每次测试集大小为 100；随机种子为 20261004。BinaryTree 的 $\sqrt{\lambda}$ 网格为 $[0.1, \sqrt{10}]$，Exponential 为 $[0.1, 2.5]$，各取 50 点并加入实际最优点。理论曲线以有限总体谱 $H_p = p^{-1} \sum_i \delta_{t_i}$ 代入式 (14)，采用式 (16) 的正根计算，是确定性等价近似；精确条件风险另由式 (11) 计算。维数扫描保持同一协方差构造规则，取 $\gamma_0 \in [0.25, 2.5]$、固定 $\lambda \in \{0.1, 1, 4\}$，用于补充原文固定比值的正则扫描。与原文的对应关系需要说明：论文图注写 BinaryTree 的 $p = 2^4$，公开代码采用 $p = 2^d - 1$；本文遵循代码并报告实际比值。公开模拟函数采用 500 次训练重复、每次 100 个测试点，正文与图注的配置记载并不完全一致。本文共享同次重复内不同正则参数的训练和测试数据，边际实验设定一致，随机波动及网格与原图不要求逐点相同。图 5 直接对应原文的六个正则路径面板；图 6 考察固定正则下的维数变化。两图统一比较总预测风险，其噪声底座为 1。 表 3 给出理论最优点的数值对照。精确条件风险的最优参数仍为 $p/(n\alpha^2)$，协方差结构主要改变风险曲线的水平和形状；测试曲线最低点受有限重复和网格影响。两种谱模型之间的风险差异，应结合整个总体谱以及 $\alpha^2 \operatorname{tr}(\Sigma)/p$ 的平均信号方差解释。对 A1 的判断分为两部分：固定 $\gamma$ 时，以正则路径核对偏差与方差平衡以及理论最优点；固定 $\lambda$ 时，以维数扫描观察插值附近的噪声放大与正则作用。正则为正时风险有限，具体峰值与协方差谱有关，不能把单位协方差图中的形状直接套用到两种模型。BinaryTree 在本次两类扫描中，测试均值与理论风险的平均绝对差为 0.0138，最大绝对差为 0.2058。这些差异同时包含有限样本近似误差和模拟误差；误差线仅量化重复均值的不确定性。Exponential 在本次两类扫描中，测试均值与理论风险的平均绝对差为 0.0142，最大绝对差为 0.1479。这些差异同时包含有限样本近似误差和模拟误差；误差线仅量化重复均值的不确定性。一般协方差加权谱公式与直接迹公式的最大差为 $4.26 \times 10^{-13}$；通用理论在单位协方差下与闭式公式的最大差为 $1.24 \times 10^{-14}$。相关核验及固定训练特征的模拟检查已随本次本地运行完成。

表 3: 两种协方差模型在理论最优点处的总预测风险。

| 模型 | 实际 $\gamma$ | $\lambda^*$ | 理论 | 条件均值 | 测试均值 ± SE |
|---|---|---|---|---|---|
| BinaryTree | 0.500 | 0.500 | 1.3576 | 1.3603 | 1.3560 ± 0.0111 |
| BinaryTree | 1.000 | 1.000 | 1.5314 | 1.5397 | 1.5300 ± 0.0141 |
| BinaryTree | 2.143 | 2.143 | 1.7096 | 1.7185 | 1.7206 ± 0.0186 |
| Exponential | 0.500 | 0.500 | 1.3196 | 1.3256 | 1.3263 ± 0.0126 |
| Exponential | 1.000 | 1.000 | 1.4890 | 1.4938 | 1.5010 ± 0.0131 |
| Exponential | 2.000 | 2.000 | 1.6609 | 1.6637 | 1.6549 ± 0.0144 |

## 参考文献

[1] Dobriban, E., and Wager, S. (2018). High-dimensional asymptotics of prediction: Ridge regression and classification. *The Annals of Statistics*, 46(1), 247–279. DOI: 10.1214/17-

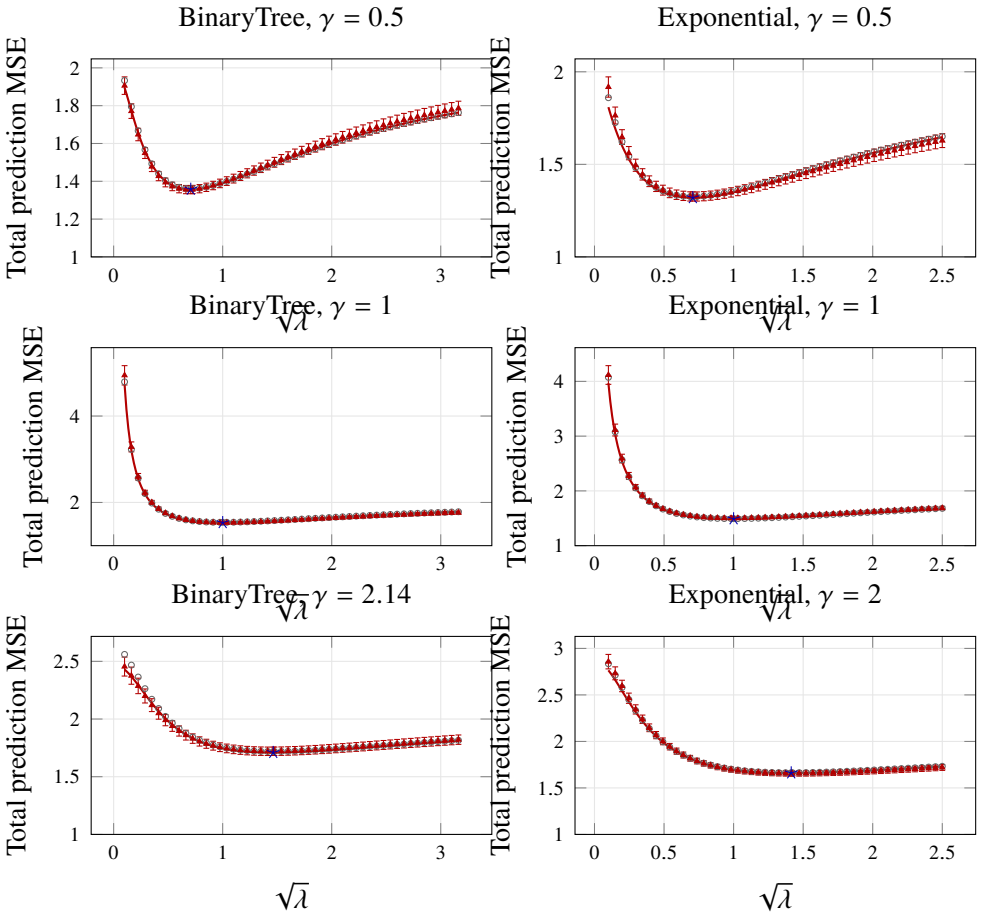



图 5: 原文图 2 的协方差模型复现：各行对应目标 $\gamma = 0.5, 1, 2$，标题记录实际 $p/n$；左列 BinaryTree，右列 Exponential，横轴统一为 $\sqrt{\lambda}$。红线为一般协方差理论风险，空心圆为精确条件风险均值，三角为独立测试 MSE 均值，误差线为近似点态 95% 区间，星号标出理论最优点。

AOS1549.

[2] Dobriban, E. *High-dimensional predictive risk: experiment code*. 作者公开实验仓库，版本 `d551acd2b3ce283e8ddf3885de4d9fc60dddd766`。模型及数值方法见 `ridge_hier_sim.m`、`ridge_exp_sim.m`、`compute_ST.m` 和 `simulate_ridge_risk_cov.m`。

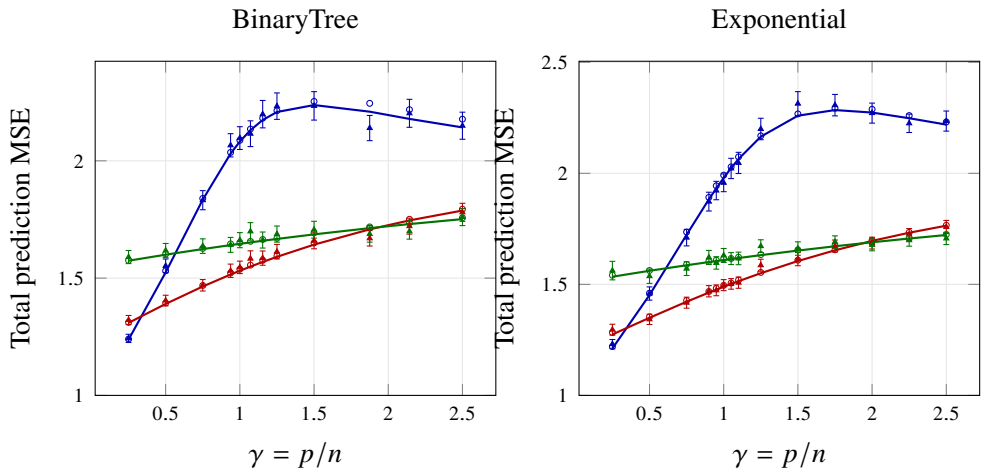



图 6: 两种协方差模型的维数样本比扫描。蓝、红、绿分别对应 $\lambda = 0.1, 1, 4$；实线连接各实际配置下的理论风险，空心圆为条件风险均值，三角及误差线为测试均值及近似点态 95% 区间。BinaryTree 固定 $p$ 改变 $n$，Exponential 固定 $n$ 改变 $p$；此图为原文实验的扩展。