A2：多岭参数模型平均复现以及与其他方法的比较

第 3 组

摘要

多岭参数模型平均通过组合不同正则化尺度的估计，扩展岭回归的谱收缩集合。我们在统一的候选网格与评价协议下，比较广义交叉验证、留一交叉验证和折外堆叠等权重选择方法，构造九种可操作估计及三个风险诊断参照，并分析信息准则与 Mallows 型风险估计的选权机制。实验覆盖欠参数、插值阈值、过参数、相关协变量、信号谱方向、异方差、重尾噪声、非线性误设、样本量和网格敏感性，共完成 9,540 次配置重复试验，对应 6,780 份不同随机种子的数据。在 36 个预设主场景中，oracle 平均相对 oracle 单一岭回归的场景平均风险比为 0.983，留一平均相对留一选参为 1.031，五折平均相对五折选参为 1.025，直接 GCV 平均相对 GCV 选参为 2.674。探索性下界实验显示，提高候选岭参数下界可缓解 GCV 平均的风险估计失真。在所考察设置中，候选凸包的 oracle 改善空间较小，实际选权误差抵消了多数场景中的组合收益，高维风险校准与候选集合控制是影响预测表现的主要因素。

关键词：模型平均；岭回归；高维预测；广义交叉验证；折外预测；插值阈值。

1 引言

高维线性预测中，岭参数决定偏差与方差的平衡，其选择误差可能与估计误差处于相同数量级。岭回归通过对样本协方差的小特征值方向施加收缩来稳定估计 (Hoerl and Kennard, 1970)。当多个岭参数对应的预测表现接近时，组合候选估计可利用其联合误差结构，组合权重的估计因而成为模型平均的核心问题。信息准则权重把模型拟合证据转换为归一化权重 (Buckland et al., 1997)，Mallows 模型平均直接优化预测损失的估计 (Hansen, 2007)，留一模型平均与折外堆叠利用未参与候选拟合的观测评估组合预测 (Hansen and Racine, 2012; Breiman, 1996)。这些准则在统计目标、噪声要求和计算代价上各有差异。Yu et al. (2018) 在不同岭参数估计之间进行凸平均，利用 GCV 型准则选择权重，并在其模型条件下证明误设模型中的渐近损失最优性。Dobriban and Wager (2018) 在比例增长和稠密随机效应框架下研究岭回归的样本外风险，刻画维数比、信号强度和总体协方差谱的作用。这两类研究分别从权重选择与高维风险分析出发，为研究多岭参数平均提供了方法和风险刻画。Zhao et al. (2020) 进一步讨论多岭参数平均的大样本性质，Patil et al. (2021) 分析高维单一岭回归交叉验证的一致性。我们在统一候选网格、权重约束、训练样本和风险定义下，比较不同权重选择方法的样本外预测风险。候选凸包上的 oracle 风险刻画多参数组合的改善空间，实际平均器与 oracle 的风险差异反映权重估计的代价。我们进一步分析插值阈值、信号谱方向和候选网格对这两部分风险的影响。

2 问题设定

设训练观测 $(x_i, y_i) \in \mathbb{R}^p \times \mathbb{R}$ 独立且来自同一未知分布，协变量 x_i 的总体均值为零、协方差为 $\boldsymbol{\Sigma} \in \mathbb{R}^{p\times p}$，其中 $\boldsymbol{\Sigma}$ 正定。设 $X \in \mathbb{R}^{n\times p}$ 的第 i 行是 $x_i^\top$，$y = (y_1, \ldots, y_n)^\top \in \mathbb{R}^n$，未知系数为 $\boldsymbol{\beta} \in \mathbb{R}^p$，条件噪声均值为零。基础模拟采用已知的总体均值与生成尺度，所有预测器均使用无截距形式，不进行样本中心化。基础模型为

$$y_i = x_i^\top \boldsymbol{\beta} + \varepsilon_i, \qquad \mathbb{E}(\varepsilon_i \mid x_i) = 0, \quad \mathbb{E}(\varepsilon_i^2) = \sigma^2, \tag{1}$$

其中基础实验取 $\sigma^2 = 1$。令 $\gamma = p/n$，考虑 $\gamma < 1$、$\gamma \approx 1$ 与 $\gamma > 1$。预测器为 $\widehat{f}(x) = x^\top \widehat{\boldsymbol{\beta}}$，统计目标是在独立测试点上最小化总预测风险 $R = \mathbb{E}\{(y_0 - \widehat{f}(x_0))^2 \mid \mathcal{D}_n\}$。该期望条件于训练样本，仅对测试点取值。式 (1)下，总风险由不可约噪声与超额预测风险组成：

$$L = (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top \boldsymbol{\Sigma} (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}), \qquad R = \sigma^2 + L. \tag{2}$$

超额预测风险是 $\boldsymbol{\Sigma}$ 加权的系数误差；当 $\boldsymbol{\Sigma} = I_p$ 时，它与未加权系数平方误差相同。式 (2)中的总体参数在模拟中已知，用于风险评价与 oracle 诊断。沿用岭回归的估计形式 (Hoerl and Kennard, 1970)，我们以样本量归一化的目标构造候选估计

$$\widehat{\boldsymbol{\beta}}_\lambda = \arg\min_{b \in \mathbb{R}^p} \left\{ n^{-1} \|y - Xb\|_2^2 + \lambda \|b\|_2^2 \right\} = (X^\top X + n\lambda I_p)^{-1} X^\top y, \tag{3}$$

其中 $\lambda > 0$，未归一化文献中的岭参数 k 与这里的尺度满足 $k = n\lambda$。固定 M 个参数 $\lambda_1 < \cdots < \lambda_M$，令 $B = (\widehat{\boldsymbol{\beta}}_{\lambda_1}, \ldots, \widehat{\boldsymbol{\beta}}_{\lambda_M}) \in \mathbb{R}^{p \times M}$，$H_m = X(X^\top X + n\lambda_m I_p)^{-1} X^\top \in \mathbb{R}^{n \times n}$。平均器定义为 $\widehat{\boldsymbol{\beta}}(w) = Bw$，权重集合为 $\Delta_M = \{w \in [0,1]^M : \mathbf{1}^\top w = 1\}$，对应平滑矩阵为 $H(w) = \sum_m w_m H_m$。所有选权方法采用相同的凸权重约束。最小范数基准定义为 $\widehat{\boldsymbol{\beta}}_0 = X^+ y$，其中 X^+ 为 Moore–Penrose 广义逆；$p < n$ 且满列秩时它等于 OLS，$p \geq n$ 时通常为插值解。多岭参数平均组合的是候选估计，其谱收缩形式可由奇异值分解表示。设 $X = U \operatorname{diag}(s_j) V^\top$ 为薄奇异值分解，令 $d_j = s_j^2/n$，则在可识别谱方向上的收缩因子为

$$g_w(d_j) = \sum_{m=1}^{M} w_m \frac{d_j}{d_j + \lambda_m}, \tag{4}$$

其中同一权重向量作用于全部谱方向。式 (4)生成的收缩曲线一般不同于以加权平均岭参数拟合的单一岭回归。候选估计共享训练数据，组合风险包含候选误差之间的协方差项。由于候选顶点属于凸包，oracle 平均的风险不高于 oracle 单一候选的风险；数据驱动平均器的预测表现还取决于 $\widehat{\boldsymbol{w}}$ 的估计误差。

3 权重选择方法

信息准则权重、直接风险估计和交叉验证构成三类选权机制。信息准则方法令 $\delta_m = \mathrm{IC}_m - \min_\ell \mathrm{IC}_\ell$，再以 $w_m \propto \exp(-\delta_m/2)$ 归一化 (Buckland et al., 1997)。其权重由单个模型分数确定，候选预测误差之间的交叉项不直接进入优化目标。贝叶斯模型平均使用依赖模型先验和边际似然的后验模型概率；预测分布的 stacking 则通过适当评分准则选权 (Yao et al., 2018)。预测密度的对数评分与均值预测的平方损失对应不同的统计目标，我们比较的是平方预测损失下的频率学派选权方法。Mallows 型路线使用拟合残差和复杂度修正。对固定 w 和同方差噪声，考虑

$$C_p(w) = n^{-1} \|y - H(w)y\|_2^2 + 2\widehat{\sigma}^2 n^{-1} \operatorname{tr}\{H(w)\}, \tag{5}$$

其中与 w 无关的常数项可以略去。Hansen (2007) 在嵌套最小二乘和受约束权重情形证明相应最优性，Wan et al. (2010) 扩展到连续权重与非嵌套设定。我们将式 (5)应用于岭平滑矩阵。异方差下，固定权重的风险修正为 $2\operatorname{tr}\{H(w)\Omega\}/n$，其中 $\Omega = \mathrm{Var}(\varepsilon \mid X)$；可行的异方差稳健方法见Liu and Okui (2013)。在 $p \geq n$ 的满行秩设计中，OLS 残差自由度为零，残差方差估计失效。Cp-known 使用已知的 $\sigma^2 = 1$，作为分离噪声估计误差的诊断参照。其同方差修正的无偏解释适用于固定权重与同方差噪声；异方差场景采用该修正时需要考虑噪声协方差结构。GCV 用平均杠杆替代逐点杠杆以减少计算 (Golub et al., 1979)。Yu et al. (2018) 的式 (2.4) 使用 $f_m = \operatorname{tr}(H_m \widehat{\Omega})$，同方差选择 $\widehat{\Omega} = I_n$ 对应通常的有效自由度形式。我们实现这一同方差版本

$$G(w) = \frac{n^{-1} \|y - H(w)y\|_2^2}{[1 - \operatorname{tr}\{H(w)\}/n]^2}, \qquad \widehat{\boldsymbol{w}}_{\mathrm{GCV}} \in \arg\min_{w \in \Delta_M} G(w), \tag{6}$$

其中 $\operatorname{tr} H(w)$ 是固定权重平滑器的自由度代理，风险评价需同时考虑权重随训练响应变化的影响。这里采用 $\widehat{\Omega} = I_n$，原方法中依赖 OLS 的异方差协方差估计需要可用的残差自由度。原有损失最优性结论依赖 $\lambda_{\min}(X^\top X/n)$ 的正下界及小杠杆条件，其目标为训练设计上的均值损失。在所考察的 $p \geq n$ 范围内，过参数设计的样本协方差为奇异矩阵，正下界条件失效。单一岭回归的交叉验证一致性分析 (Patil et al., 2021) 针对候选岭路径。

留一模型平均最小化逐个删除观测后产生的组合误差 (Hansen and Racine, 2012)。令 $\widehat{\boldsymbol{\beta}}_m^{(-i)}$ 使用删除第 i 个样本后的式 (3)拟合，定义 $e_{im}^{\mathrm{loo}} = y_i - x_i^\top \widehat{\boldsymbol{\beta}}_m^{(-i)}$。令 $E^{\mathrm{loo}} \in \mathbb{R}^{n\times M}$ 收集这些残差，取

$$\widehat{\boldsymbol{w}}_{\mathrm{LOO}} \in \arg\min_{w\in\Delta_M} n^{-1}\|E^{\mathrm{loo}} w\|_2^2. \tag{7}$$

权重总和为一使残差组合等于响应减去候选预测组合。留一残差用于估计权重，最终平均器的泛化误差由独立外层测试集或嵌套交叉验证评价。折外堆叠使用五折预测构造组合误差。我们对每个验证折用其余训练折拟合全部 M 个候选，构造 E^{cv}，再最小化 $n^{-1}\|E^{\mathrm{cv}} w\|^2$。该方法在Breiman (1996) 的非负 stacking 约束上加入权重总和为一的条件。为分析权重稳定化对预测风险的影响，我们进一步构造向均匀权重收缩的变体

$$\widehat{\boldsymbol{w}}_{\mathrm{reg}} \in \arg\min_{w\in\Delta_M} \left\{ n^{-1}\|E^{\mathrm{cv}} w\|_2^2 + \eta \widehat{v}_y \|w - \mathbf{1}/M\|_2^2 \right\}, \quad \widehat{v}_y = n^{-1}\sum_i y_i^2, \tag{8}$$

其中基础实验预设 $\eta = 0.01$，敏感性实验考察 $0, 0.001, 0.01, 0.1, 1$。二次惩罚限制权重偏离均匀分配的程度，同时增加部分预测质量较差候选的权重，形成权重稳定性与组合偏差之间的权衡。

4 实现方案与比较协议

我们对每个训练折进行一次薄奇异值分解，再以 $s_j/(s_j^2 + n\lambda_m)$ 同时生成整条岭路径。这一计算在欠参数和过参数设计中均可实施。训练与五折拟合按当前训练样本量归一化，五折候选因而使用 $n_{-k}\lambda_m$。在所设定的无截距模拟中，插值阈值位于 $p = n$。真实数据应用中的中心化、尺度估计和不惩罚截距应在各训练折内处理，留一快捷式也需与相应的拟合步骤一致。设 $E = (y - H_1 y, \ldots, y - H_M y)$，$a_m = 1 - \operatorname{tr}(H_m)/n$。正岭参数网格使 $a_m > 0$。通过变换 $v_m = a_m w_m/(a^\top w)$，GCV 的分式优化等价于凸二次规划

$$\widehat{v} \in \arg\min_{v\in\Delta_M} n^{-1}\|E\operatorname{diag}(a)^{-1} v\|_2^2, \qquad \widehat{w}_m = \frac{\widehat{v}_m/a_m}{\sum_\ell \widehat{v}_\ell/a_\ell}, \tag{9}$$

优化变量 v 经逆变换得到原平均器的权重 w。LOO、五折和式 (8)同样采用凸二次规划，我们使用解析梯度与单纯形约束求解。每次求解最多采用均匀点和最优顶点两个初值，并记录收敛状态与归一化的一阶最优性间隙。全部运行的求解器成功返回，最大间隙为 $3.23e-05$。留一拟合采用删除观测后的样本量归一化。令 $\widetilde{H}_m = X\{X^\top X + (n-1)\lambda_m I_p\}^{-1} X^\top$，利用

$$e_{im}^{\mathrm{loo}} = \frac{y_i - (\widetilde{H}_m y)_i}{1 - (\widetilde{H}_m)_{ii}}, \tag{10}$$

计算式 (7)。$\widetilde{H}_m$ 使用 $(n-1)\lambda_m$ 的惩罚，与全样本 H_m 对应不同的正则化尺度。我们在欠参数与过参数小矩阵上将该公式与逐样本删除重拟合核对，最大绝对误差小于 6×10^{-12}。最小范数解的数值秩阈值取 $\max(n,p)\epsilon_{\mathrm{mach}} s_{\max}$，并与广义逆计算核对；总体协方差平方根通过重构误差检查。九种可操作估计包括 GCV、LOO、五折选出的单一 ridge，等权平均，GCV-MA、LOO-MA、5CV-MA、5CV-MA-Reg 和 MinNorm。等权平均使用相同的正岭参数网格，$\lambda = 0$ 的最小范数解作为独立基准。三个诊断参照为 Cp-known、Oracle-Ridge 和 Oracle-MA。Oracle-Ridge 最小化候选 L_m，Oracle-MA 在 Δ_M 上最小化式 (2)；二者使用真实 $\boldsymbol{\beta}, \boldsymbol{\Sigma}$，刻画候选集合的风险下界和权重估计代价。Cp-known 与两类 oracle 使用的总体信息在实际拟合中未知，因而与可操作方法分别评价。可操作方法以 X, y、候选参数和预设折分为输入，真实总体参数与独立测试数据在选权完成后进入评价。

5 数值实验

主实验固定 $n = 100$，取 $\gamma \in \{0.5, 0.8, 0.95, 1, 1.05, 1.2, 1.5, 2, 3\}$，$p$ 为 $n\gamma$ 的整数值。协方差为 I_p 或 Toeplitz 矩阵 $\Sigma_{jk} = 0.7^{|j-k|}$，稠密系数从独立标准正态方向生成，再归一化到 $\boldsymbol{\beta}^\top \boldsymbol{\Sigma} \boldsymbol{\beta} \in \{1, 5\}$，使其等于基础信噪比。我们在每个场景独立生成 120 份训练样本，并在同一份数据上比较全部方法。候选网格预设 $M = 21$，$\lambda_m = 10^{-4+6(m-1)/(M-1)}$。所有选参和选权共享候选集合，五折单一 ridge 与五折平均共享折分。主实验共 36 个场景、4320 次重复，风险汇总包含全部预设随机种子。扩展实验在 $n = 100, \gamma = 1.5$, 信噪比 1 下设置八个压力场景，每个重复 150 次。四个使用各向异性对角协方差，其特征值按从 0.05 到 5 的几何序列排列并归一化平均值为一，分别考虑稠密方向、最大 10% 特征值子空间、最小 10% 特征值子空间和随机 10% 非零系数。其余四个使用 Toeplitz 协方差，分别设置异方差 $\varepsilon_i = \sqrt{0.25 + 0.75 x_{i1}^2}\, z_i$，方差归一化的 $t_3/\sqrt{3}$ 噪声，随机 10% 稀疏信号，以及均值误设 $y_i = x_i^\top \boldsymbol{\beta} + (x_{i1}^2 - 1)/\sqrt{2} + \varepsilon_i$。这里 z_i 为标准正态且独立于设计。各向异性实验保持总信号方差一致，弱方向信号对应较大的系数范数，因此信号方向变化同时影响预测难度与未加权系数估计难度。

样本量实验取 $n = 60, 200$，结合 $\gamma = 0.8, 1.5, 3$ 与两种协方差，每场景重复 100 次。网格实验在 Toeplitz、$n = 100, \gamma = 1.5$ 下比较 $M = 5, 11, 21, 41$，再比较窄区间 $[10^{-1.5}, 10^{0.5}]$ 和高下界区间 $[1, 10^3]$，每场景重复 120 次。惩罚敏感性实验也重复 120 次。针对观察到的 GCV 风险失真，我们构造探索性下界诊断：在 Toeplitz、$\gamma = 1, 1.5$ 下改变 $\lambda_{\min} \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1\}$，保持 $\lambda_{\max} = 100$ 和 $M = 21$，每配置重复 150 次。网格、惩罚与下界实验使用共同随机种子和折分，数据共享计入不同种子数据的总数。全部实验包含 77 个配置、9,540 次配置重复试验、6,780 份不同种子数据，对应 114,480 条方法级记录。

表 1: 信噪比 1 的代表主场景。单元格为平均超额风险（Monte Carlo 标准误），每场景 120 次重复。Oracle-MA 仅作不可实施的诊断参照。

设计	p/n	Ridge-GCV	Equal	GCV-MA	LOO-MA	5CV-MA	Oracle-MA
独立	0.5	0.443 (0.008)	0.486 (0.012)	0.471 (0.013)	0.447 (0.010)	0.448 (0.009)	0.401 (0.008)
独立	1	1.245 (0.286)	3.104 (0.112)	8.756 (1.069)	0.862 (0.055)	0.725 (0.019)	0.604 (0.006)
独立	1.5	0.766 (0.012)	1.070 (0.013)	1.366 (0.067)	0.774 (0.008)	0.772 (0.007)	0.716 (0.005)
独立	3	0.882 (0.006)	0.927 (0.005)	0.985 (0.013)	0.877 (0.005)	0.878 (0.005)	0.841 (0.003)
相关	0.5	0.309 (0.008)	0.386 (0.008)	0.317 (0.008)	0.307 (0.008)	0.304 (0.008)	0.273 (0.007)
相关	1	0.649 (0.142)	1.821 (0.049)	5.014 (0.611)	0.576 (0.053)	0.472 (0.015)	0.396 (0.007)
相关	1.5	0.593 (0.017)	0.962 (0.016)	1.315 (0.089)	0.599 (0.012)	0.585 (0.010)	0.519 (0.008)
相关	3	0.725 (0.009)	0.872 (0.011)	0.920 (0.030)	0.731 (0.009)	0.733 (0.009)	0.678 (0.006)

主要指标为式 (2)的条件超额预测风险，辅助指标包括总预测风险、系数平方误差、固定权重自由度代理、有效候选数 $M_{\text{eff}} = 1/\sum_m w_m^2$、拟合加选权时间，以及每次独立生成 1000 个测试点的测试 MSE。非线性误设下，高斯设计使二次项与任意线性预测正交，因而 $L = (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top \boldsymbol{\Sigma} (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}) + 1$，总风险再加噪声方差 1。我们采用解析风险减少有限测试集的随机误差，测试 MSE 用于核验评价实现。统计汇总使用全部重复，误差带为均值加减 1.96 倍 Monte Carlo 标准误；方法比较使用共同重复上的 2000 次成对 bootstrap 风险均值比区间，区间按场景计算，未作多重比较校正。t_3 的四阶矩不存在，该场景报告均值风险比；$p = n$ 时最小范数风险以中位数和四分位区间描述。在所考察设置中，GCV-MA 在插值附近的预测风险和重复间波动高于单一 GCV ridge（图 1）。表 1列出信噪比 1 的代表场景：独立设计 $\gamma = 1$ 时，Ridge-GCV 的平均超额风险为 1.245，GCV-MA 为

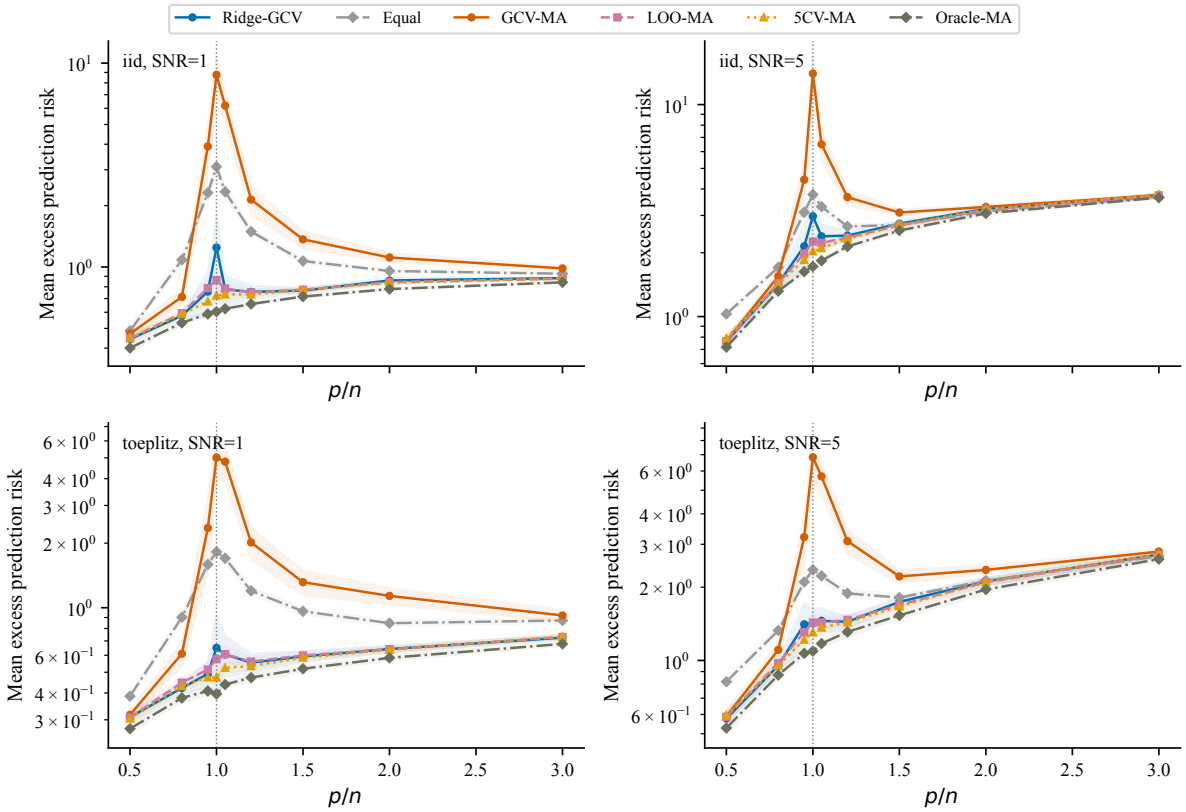


图 1: 主实验的平均超额预测风险。四个面板分别为独立或相关设计与信噪比 1 或 5，横轴为 p/n，纵轴采用对数尺度。曲线使用全部 120 次重复，阴影为描述性均值误差带。MinNorm 的插值风险单独在图 2显示，全部方法的逐场景结果保存在结果表中。

8.756，LOO-MA 为 0.862；相关设计 $\gamma = 1.5$ 时，这三个值分别为 0.593、1.315、0.599。五折平均在插值附近相对 Ridge-GCV 的风险较低，这一差异同时涉及验证准则与组合方式；同准则比较进一步分离组合所带来的风险变化。最小范数估计的风险峰值集中于插值阈值附近（图 2），与Hastie

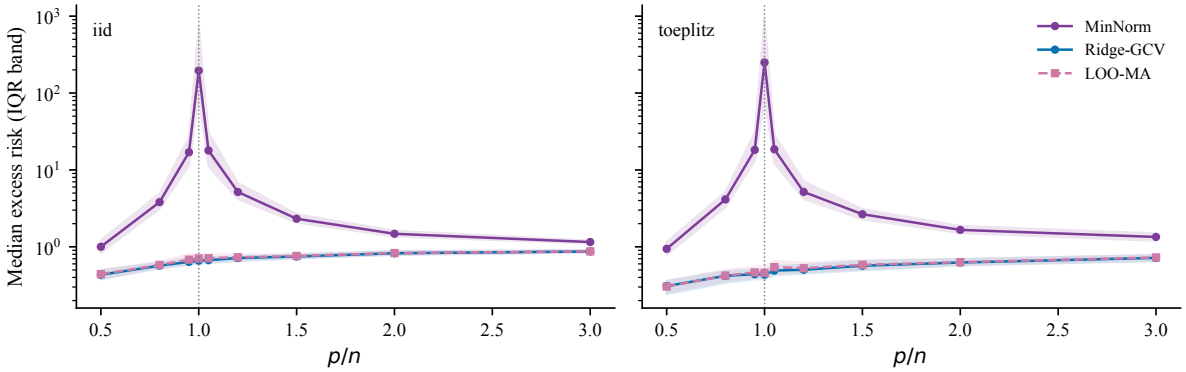


图 2: 信噪比 1 时最小范数、单一 GCV ridge 与留一平均的超额风险中位数和四分位区间。横轴包含 $p = n$，纵轴为对数尺度，阴影表示四分位区间。

et al. (2022) 关于无岭最小二乘的风险分析一致。在有限样本中，$p = n$ 的高斯方阵可能产生极小奇异值，使噪声在相应谱方向上被放大。严格正岭参数限制了这些方向上的放大程度。风险汇总保留全部极端重复，完整原始风险保存于 `raw.csv`。

同准则比较显示，36 个主场景中 Oracle-MA 相对 Oracle-Ridge 的场景平均风险比为 0.983，范围为 0.969–0.999，基础稠密设计上的 oracle 改善幅度较小（图 3）。LOO-MA 的对应平均比值

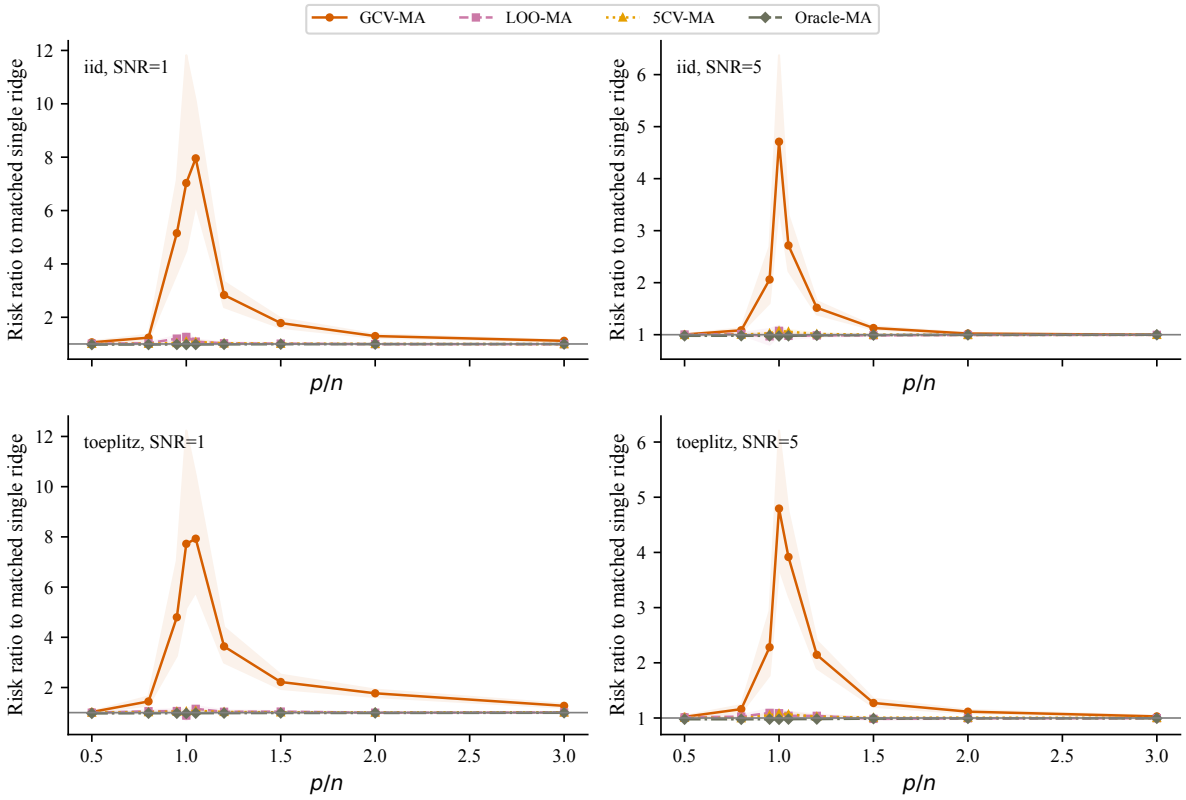


图 3: 平均相对同一准则单一 ridge 的超额风险均值比。GCV-MA、LOO-MA、5CV-MA 分别与 Ridge-GCV、Ridge-LOO、Ridge-5CV 比较，Oracle-MA 与 Oracle-Ridge 比较。小于一表示平均改善，阴影为逐场景成对 bootstrap 区间。

为 1.031，其中 14 个场景的点估计低于一；5CV-MA 为 1.025，其中 6 个场景低于一。GCV-MA 的平均比值为 2.674，范围为 0.998–7.956。这些汇总值是预设 36 个场景风险比的等权平均。我们通过共同重复上的成对风险差值和比值区间评估方法差异（表 2）。

表 2: 相关设计、信噪比 1 的同准则成对比较。差值为平均器减去单一选参器，括号为成对差值的 Monte Carlo 标准误；比值区间使用 2000 次成对 bootstrap。

p/n	平均器 / 选参器	风险比	风险差（标准误）	比值区间
0.5	GCV-MA/Ridge-GCV	1.026	0.008 (0.003)	[1.004, 1.048]
0.5	LOO-MA/Ridge-LOO	0.996	-0.001 (0.002)	[0.983, 1.008]
0.5	5CV-MA/Ridge-5CV	1.005	0.002 (0.002)	[0.990, 1.021]
1	GCV-MA/Ridge-GCV	7.723	4.364 (0.606)	[5.162, 12.234]
1	LOO-MA/Ridge-LOO	0.882	-0.077 (0.094)	[0.703, 1.153]
1	5CV-MA/Ridge-5CV	1.051	0.023 (0.009)	[1.017, 1.093]
1.5	GCV-MA/Ridge-GCV	2.220	0.723 (0.086)	[1.944, 2.510]
1.5	LOO-MA/Ridge-LOO	1.040	0.023 (0.005)	[1.022, 1.057]
1.5	5CV-MA/Ridge-5CV	1.012	0.007 (0.005)	[0.995, 1.029]
3	GCV-MA/Ridge-GCV	1.270	0.196 (0.028)	[1.195, 1.345]
3	LOO-MA/Ridge-LOO	1.007	0.005 (0.004)	[0.996, 1.018]
3	5CV-MA/Ridge-5CV	1.008	0.006 (0.003)	[0.999, 1.017]

压力实验显示，信号谱方向影响单一 ridge 与平均器的绝对风险，GCV-MA 在这些场景中仍表现出较高的预测风险（图 4）。总信号方差相同时，弱特征值方向的信号更难恢复，强特征值方向的信号更易预测。在所考察的异方差、重尾和非线性误设场景中，LOO-MA 与正则化五折平均

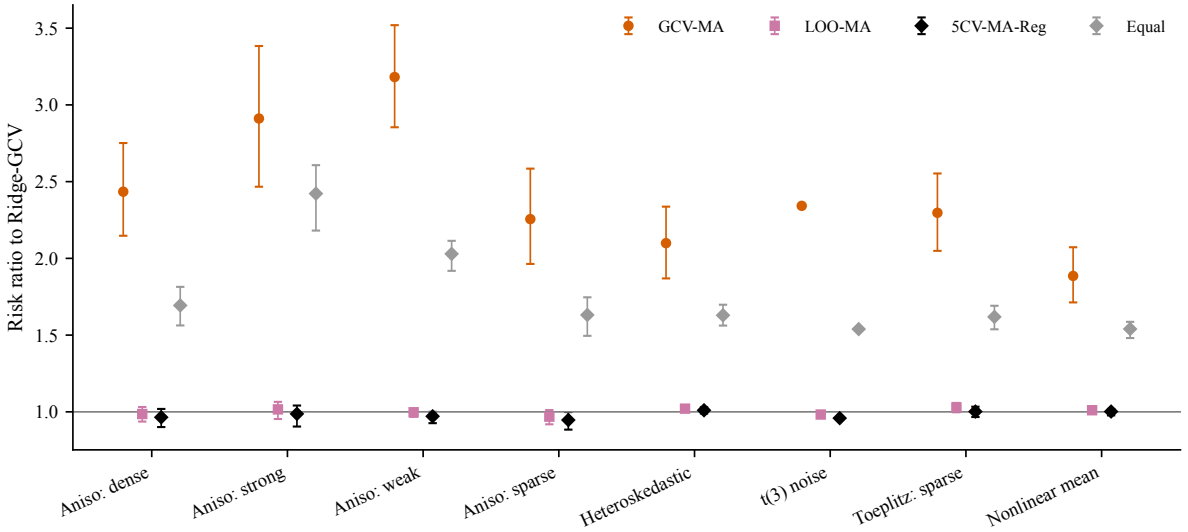


图 4: 八个压力场景相对 Ridge-GCV 的超额风险均值比，每场景重复 150 次。各向异性四组依次为稠密、强特征值方向、弱特征值方向和稀疏信号，后三类噪声及误设设置见正文。除 t_3 点只报告均值比外，误差棒为逐场景成对 bootstrap 区间。该图的参照统一为 Ridge-GCV，平均机制的同准则比较另见结果表。

的风险多数接近单一 Ridge-GCV。非线性误设引入大小为一的线性近似损失，这一共同常数压缩了风险比的相对差异；线性系数部分的风险差异需在扣除该项后分析。在 $n = 60, 100, 200$ 的样

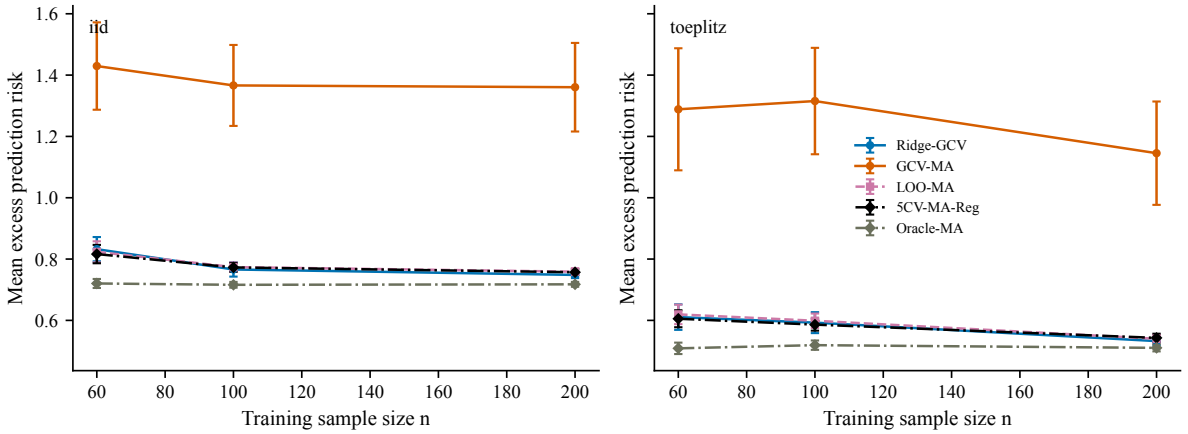


图 5: 信噪比 1、$\gamma = 1.5$ 下样本量变化。$n = 60, 200$ 使用 100 次重复，$n = 100$ 使用主实验的 120 次重复。纵轴为解析超额预测风险，误差棒为描述性 Monte Carlo 误差带。各组保持维数比固定，p 随 n 共同增加。

本量范围内，GCV-MA 与其他方法之间的风险差距持续存在（图 5）。这些比较保持 p/n 固定，反映维数与样本量共同增长时的预测表现。候选数与网格覆盖对风险具有不同影响（图 6）。在 $M = 5, 11, 21, 41$ 下，LOO-MA 的平均风险分别为 0.602、0.599、0.599、0.599，Oracle-MA 相应为 0.533、0.520、0.519、0.519。网格加密降低了 oracle 风险，而 LOO-MA 的风险在较密网格上趋于稳定，反映候选离散化改善与实际选权误差之间的差异。等权平均的风险对网格端点较为敏感，因为端点决定了均匀权重对应的收缩分布。高下界网格在该场景中改善了预测表现，进一步体现候选集合覆盖对风险的影响。未正则化权重经常集中于少数候选，正则化五折权重的分配较为分散（图 7）。21 个候选的岭路径预测高度相关，多组权重可对应相近的组合预测，单个 λ 上的权重因而可能具有较弱的可识别性。M_{eff} 描述权重集中程度，预测稳定性则需结合风险与组合系数共同分析。增加惩罚提高了权重分散程度，同时伴随预测风险上升（图 8）。$\eta = 0$ 到 1 的平均风险为 0.585、0.585、0.586、0.591、0.618，有效候选数由 1.82 增至 14.43。基础比较采用预设的 $\eta = 0.01$，其余惩罚水平用于敏感性分析。探索性下界实验显示，在 $\gamma = 1$ 时，将下界从 10^{-4} 提

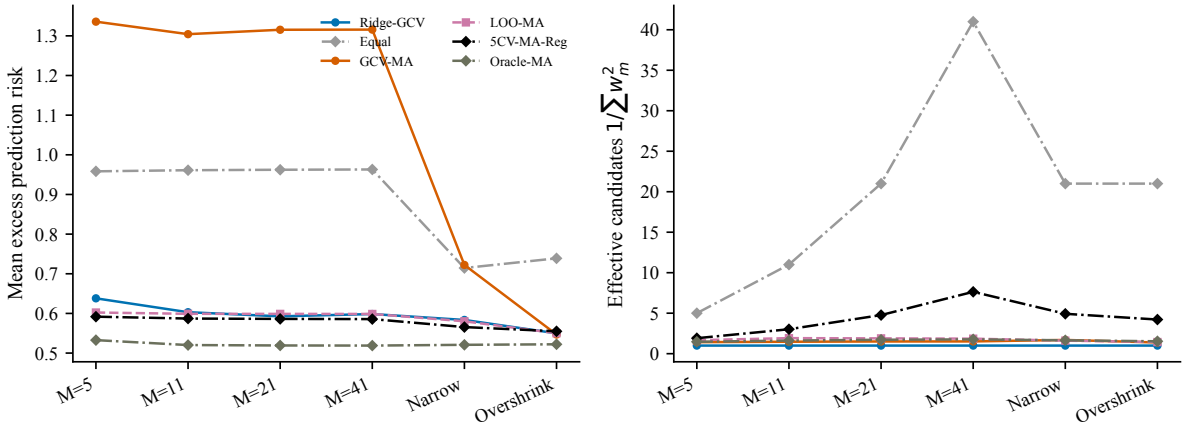


图 6: 相关设计、$n = 100, \gamma = 1.5$、信噪比 1 下的候选网格敏感性。前四组共用 $[10^{-4}, 100]$、改变 M；Narrow 为 $[10^{-1.5}, 10^{0.5}]$，Overshrink 为 $[1, 10^{3}]$，两者均取 $M = 21$。左图显示实际超额风险，右图显示有效候选数，全部配置使用相同的 120 份数据。Overshrink 对应偏向较强收缩的高下界网格。

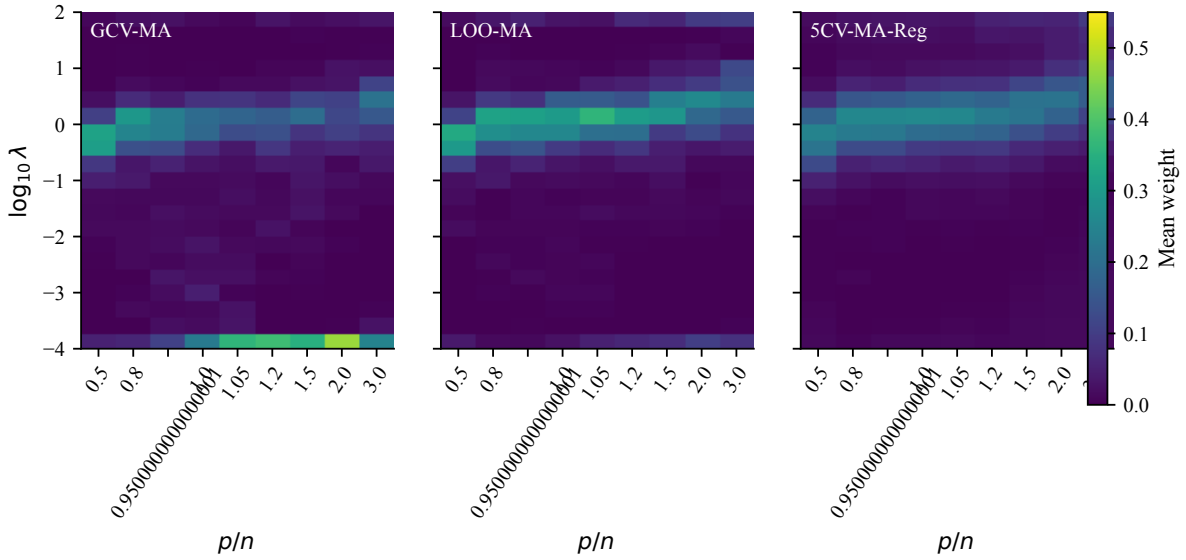


图 7: 相关设计、信噪比 1 下的平均权重路径。每格为主实验 120 次重复上的权重均值，横轴为维数比，纵轴为 $\log_{10}\lambda$。各面板共用上界为 0.55 的色标，原始权重按实际取值计算。

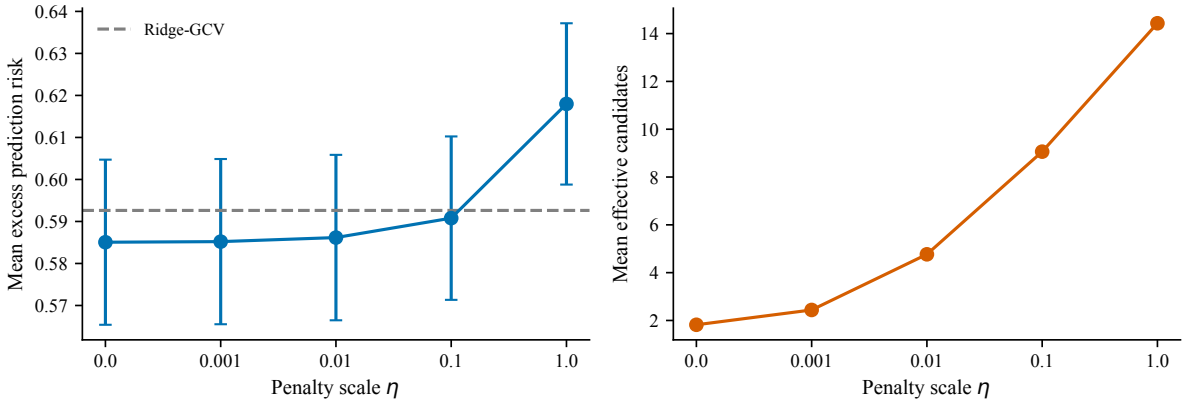


图 8: 均匀权重惩罚的敏感性，使用相关设计、$n = 100, \gamma = 1.5$、信噪比 1 的相同 120 份数据。左图为正则化五折平均的超额风险，虚线为同一数据上的 Ridge-GCV；右图为有效候选数。惩罚尺度为 η 乘以训练响应二阶矩。

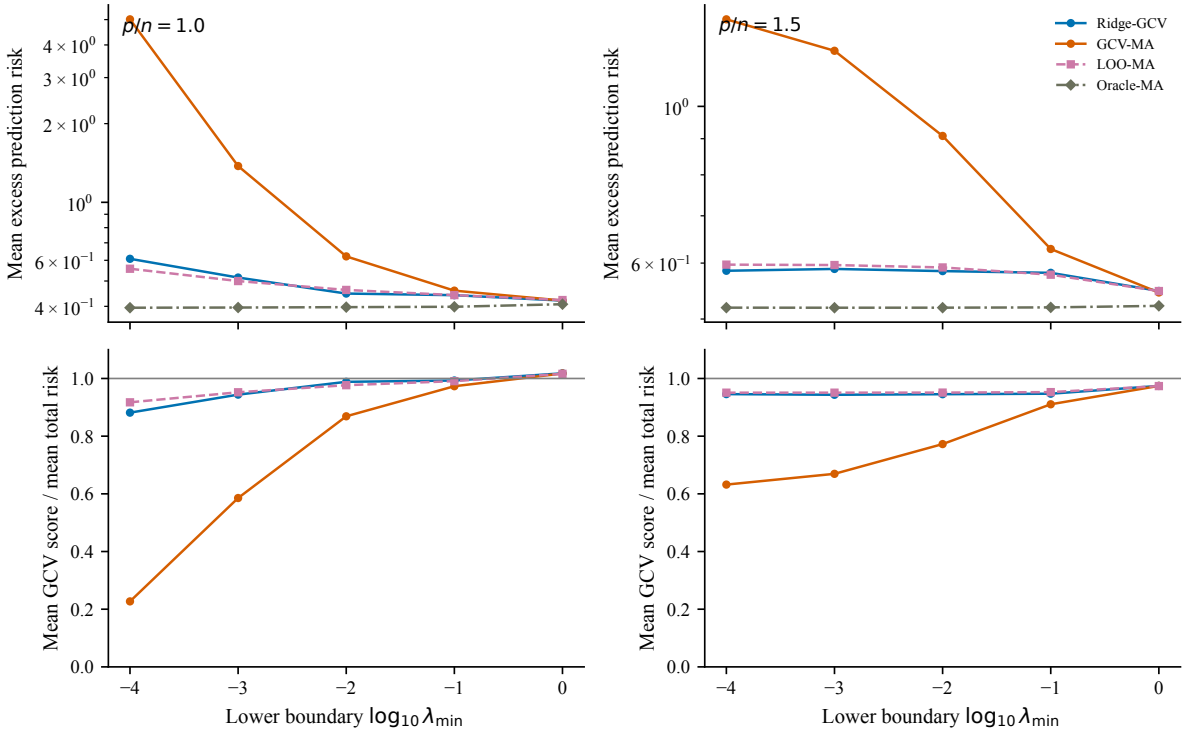


图 9: 探索性下界诊断，每配置使用 150 份共同随机种子数据。上排为实际超额风险，下排为平均 GCV 分数除以平均总预测风险，分母包含不可约噪声。比值接近一对应汇总均值层面的校准。横轴改变网格下界，其余设置为相关设计、信噪比 1、$M = 21, \lambda_{\max} = 100$。

高到 1，GCV-MA 的平均超额风险由 5.012 降至 0.421，GCV 分数与真实总风险的均值比由 0.227 变为 1.017（图 9）。接近插值的候选使残差和自由度分母同时很小，沿组合方向降低 GCV 分数可能伴随较高的样本外风险。式 (9)的逆变换对很小的 a_m 放大相应权重，与这一边界机制一致。提高下界缩小了候选模型族，同时改变可实现的收缩曲线与近似偏差。五折选权的额外计算开销主要

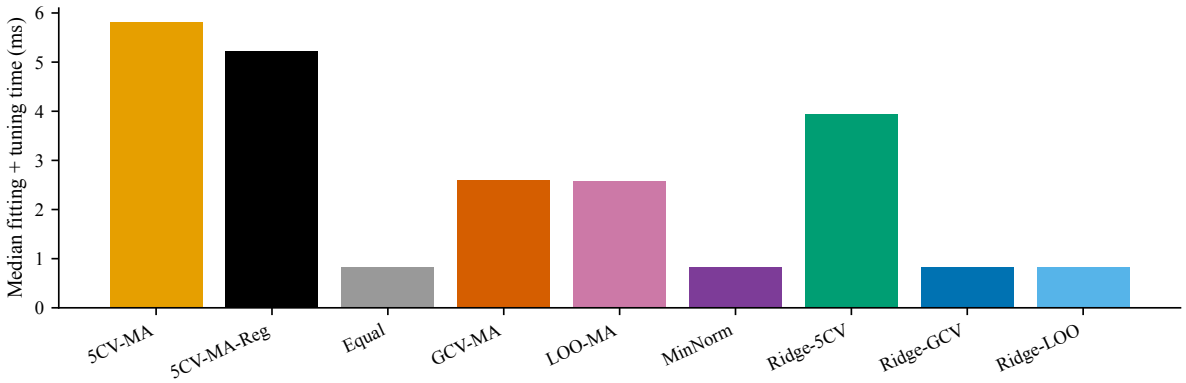


图 10: 九种可操作估计的拟合加选权时间中位数，汇总主实验全部重复，单位为毫秒。时间按共享全样本分解、相应五折分解与选权求解相加，不重复计入不相关方法的工作；同一分解同时生成整条候选路径。测量环境为本机四进程、每进程单线程，属于该实现与硬件的经验成本。

来自五次训练折拟合，解析留一则复用全样本谱分解（图 10）。共享分解使整条岭路径的生成与单次分解相结合，降低了多候选比较的计算成本。

6 讨论

在基础稠密设计中，即使采用 oracle 权重，模型平均相对于单一 ridge 的风险改善也较小。实际选权引入的误差进一步抵消了多数场景中的收益。因此，这些设置下模型平均的表现主要取决于能否准确估计权重。同一准则下的单一 ridge 为这一比较提供了直接参照；最小范数估计和等权平均则帮助我们判断，风险变化有多少来自插值附近的不稳定性和候选网格的覆盖范围。直接 GCV 平均对包含极小岭参数的网格尤为敏感，其风险估计明显偏低。提高参数下界后，预测风险和校准表现随之变化，说明候选网格的选择需要与选权准则一起考虑。我们使用独立训练样本考察了有限样本表现。将这些结果推广到比例高维极限，需要分析 GCV 在整个混合平滑器族上的校准误差，并确定如何从训练数据中选择正则化下界。重尾实验中的 150 次重复对极端尾部覆盖有限，插值处的最小范数风险均值也容易受少数极端样本影响。这两类结果需要更多重复来判断其稳定性。应用层面的检验还应包括真实数据、响应相关的抽样以及训练与测试分布漂移，其中样本依赖会改变岭回归风险和交叉验证的校准表现 (Atanasov et al., 2025)。对于稀疏设计，加入 lasso 等方法，才能评价岭估计及其组合相对于稀疏估计的表现。

A 代数说明与复现核验

令 $q = a^\top w > 0$。由式 (6)和权重总和为一可得 $G(w) = \|Ew\|^2/(nq^2)$。定义 $v_m = a_m w_m/q$，则 $v \in \Delta_M$。令 $c = \sum_m v_m/a_m$，逆变换 $w_m = (v_m/a_m)/c$ 满足 $w \in \Delta_M$ 且 $a^\top w = 1/c$，从而

$$\frac{Ew}{a^\top w} = E\,\mathrm{diag}(a)^{-1} v.$$

因此，式 (9)与原目标具有相同最优值，且可行权重一一对应；这一等价关系的适用条件为固定候选矩阵和正分母。令 $A_m = (X^\top X + n\lambda_m I_p)^{-1} X^\top$，$A(w) = \sum_m w_m A_m$。对固定 X 和非随机 w，式 (1)下的训练噪声期望满足

$$\mathbb{E}\{L(w) \mid X\} = \{A(w)X\boldsymbol{\beta} - \boldsymbol{\beta}\}^\top \boldsymbol{\Sigma} \{A(w)X\boldsymbol{\beta} - \boldsymbol{\beta}\} + \mathrm{tr}\{\boldsymbol{\Sigma} A(w) \Omega A(w)^\top\},$$

其中 $\Omega = \mathrm{Var}(\varepsilon \mid X)$。方差项包含全部 $w_m w_\ell \,\mathrm{tr}(\boldsymbol{\Sigma} A_m \Omega A_\ell^\top)$，刻画候选误差的联合结构。对于响应依赖的权重 $\widehat{\boldsymbol{w}}(y)$，风险分解还需处理权重与训练噪声之间的依赖。

`code/experiment.py` 实现数据生成、拟合和评价，`code/analyze.py` 从原始记录生成图表，`code/build_report.py` 将计算数值与表格填入正文，`code/verify.py` 检查岭路径、留一公式、单纯形约束、oracle 优势、协方差重构和求解诊断。主随机种子为 20261007，各数据生成配置与重复编号派生独立子种子；网格和惩罚比较共享数据配置编号。可操作方法在同一数据上比较，oracle 在拟合后用于风险评价。环境版本与代码散列保存于 `results/metadata.json`，数值核验保存于 `results/verification.json`。编译使用 XeLaTeX 和中文 Fandol 字体，插图为可独立导出的矢量 PDF。

参考文献

Atanasov, Alexander; Zavatone-Veth, Jacob A.; Pehlevan, Cengiz (2025). Risk and cross validation in ridge regression with correlated samples. *Proceedings of Machine Learning Research*, 267, 1887–1930. https://proceedings.mlr.press/v267/atanasov25a.html.

Breiman, Leo (1996). Stacked regressions. *Machine Learning*, 24, 49–64. https://doi.org/10.1007/BF00117832.

Buckland, S. T.; Burnham, K. P.; Augustin, N. H. (1997). Model selection: An integral part of inference. *Biometrics*, 53, 603–618. https://doi.org/10.2307/2533961.

Dobriban, Edgar; Wager, Stefan (2018). High-dimensional asymptotics of prediction: Ridge regression and classification. *The Annals of Statistics*, 46, 247–279. https://doi.org/10.1214/17-AOS1549.

Golub, Gene H.; Heath, Michael; Wahba, Grace (1979). Generalized cross-validation as a method for choosing a good ridge parameter. *Technometrics*, 21, 215–223. https://doi.org/10.1080/00401706.1979.10489751.

Hansen, Bruce E. (2007). Least squares model averaging. *Econometrica*, 75, 1175–1189. https://doi.org/10.1111/j.1468-0262.2007.00785.x.

Hansen, Bruce E.; Racine, Jeffrey S. (2012). Jackknife model averaging. *Journal of Econometrics*, 167, 38–46. https://doi.org/10.1016/j.jeconom.2011.06.019.

Hastie, Trevor; Montanari, Andrea; Rosset, Saharon; Tibshirani, Ryan J. (2022). Surprises in high-dimensional ridgeless least squares interpolation. *The Annals of Statistics*, 50, 949–986. https://doi.org/10.1214/21-AOS2133.

Hoerl, Arthur E.; Kennard, Robert W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12, 55–67. https://doi.org/10.1080/00401706.1970.10488634.

Liu, Qingfeng; Okui, Ryo (2013). Heteroscedasticity-robust Cp model averaging. *The Econometrics Journal*, 16, 463–472. https://doi.org/10.1111/ectj.12009.

Patil, Pratik; Wei, Yuting; Rinaldo, Alessandro; Tibshirani, Ryan (2021). Uniform consistency of cross-validation estimators for high-dimensional ridge regression. *Proceedings of Machine Learning Research*, 130, 3178–3186. https://proceedings.mlr.press/v130/patil21a.html.

Wan, Alan T. K.; Zhang, Xinyu; Zou, Guohua (2010). Least squares model averaging by Mallows criterion. *Journal of Econometrics*, 156, 277–283. https://doi.org/10.1016/j.jeconom.2009.10.030.

Yao, Yuling; Vehtari, Aki; Simpson, Daniel; Gelman, Andrew (2018). Using stacking to average Bayesian predictive distributions (with discussion). *Bayesian Analysis*, 13, 917–1003. https://doi.org/10.1214/17-BA1091.

喻达磊、饶炜东、尹潇潇 (2018). 岭回归中基于广义交叉核实法的最优模型平均估计. *系统科学与数学*, 38, 652–661. https://doi.org/10.12341/jssms13408.

Zhao, Shangwei; Liao, Jun; Yu, Dalei (2020). Model averaging estimator in ridge regression and its large sample properties. *Statistical Papers*, 61, 1719–1739. https://doi.org/10.1007/s00362-018-1002-4.