# 多岭参数平均的风险、信号谱对齐与选权代价

B 计划首轮研究报告与复现实验

2026 年 11 月 4 日　代码、原始结果与数学证明配套交付

**摘要**

本研究从同一训练数据、多个正则参数的岭回归平均出发，建立一般系数先验下的精确条件风险矩阵，给出各向同性情况下可由单参数 resolvent 差商计算的高维极限，并区分连续单岭基准、平均家族的可达收益和训练数据选权造成的损失。主实验包含 18 个配置、每配置 100 次独立重复，共 1 800 份训练数据、21 600 条方法记录；另以 300 份数据验证普通 GCV 的极限反例，以 720 份数据验证有界谱下的确定性等价。各向同性控制中，连续单岭与先验平均 oracle 混合风险一致；弱谱方向的信号方差提高时，凸平均存在小幅结构收益；强谱方向更突出时，受约束负权重可扩大可达收益。但本次实际选权没有实现这些 oracle 收益：校正与 LOO 显著改善普通 GCV 平均，仍未优于单岭调参。这支持将后续问题聚焦于稳定选权，而不能宣称已提出普遍优于岭回归的新方法。

## 1　已完成的工作与主要结论

1. **风险公式已实现并核验**。一般先验协方差 $\Psi$ 下直接计算完整交叉风险，保留 $p > n$ 的样本零空间；各向同性极限的方差交叉项包含 $S = X^{\mathsf{T}}X/n$，没有将其错误替换为偏差项。

2. **信号结构确实影响平均的可达收益，但幅度小**。当 $b - a = -0.3$，六个配置的凸平均条件风险收益范围为 0.000904 至 0.002874；当 $b - a = +0.3$，负权重 oracle 的收益范围为 0.000457 至 0.001372。这些是总风险的绝对差，不能误读成百分数。各向同性控制的最大逐次风险偏差小于 $10^{-12}$。

3. **普通 GCV 的失准有明确代数机制**。普通聚合 GCV 与逐候选交叉残差准则可由同一个单纯形二次规划求解，但前者将解按 $1/(1 - \mathrm{df}_j/n)$ 再加权，可能放大高自由度候选。两者最小分数相同，并不意味着拟合出的模型或实际风险相同。

4. **有限样本选权仍是主要代价**。在全部 18 个配置中，本次交叉残差、LOO 及受约束负权重选权的平均风险仍高于连续单岭 oracle；不能将固定权重校准有效直接解释为自适应选权已经达到最优。

本文的风险恒等式、代数推导和模拟用于课程项目的可核验推广。多岭参数平均、source condition、正则外推与交叉风险校正均已有相关研究 [7, 2, 4, 3]；本报告不据此宣称论文级原创性已确认。

## 2 实验设计、信息范围与计算方法

总体特征基中令 $\Sigma = \mathrm{diag}(\mu_1, \ldots, \mu_p)$，系数先验为 $\beta \sim N(0, \Psi)$，$\Psi = \mathrm{diag}(\psi_1, \ldots, \psi_p)$，训练特征行为 $N(0, \Sigma)$，噪声为独立 $N(0, 1)$。主实验固定 $n = 100$、$p/n \in \{0.8, 1, 1.5\}$、$a \in \{1.5, 2\}$，并取

$$\mu_i = \frac{p\, i^{-a}}{\sum_{\ell=1}^{p} \ell^{-a}}, \qquad \psi_i = \frac{i^{a-b}}{\sum_{\ell=1}^{p} \mu_\ell \ell^{a-b}}, \qquad b - a \in \{-0.3, 0, 0.3\}. \tag{1}$$

于是 $\mathrm{tr}\,\Sigma = p$，$\mathbb{E}[\beta^\top \Sigma \beta] = 1$，总体预测信噪比始终为 1；$b = a$ 时 $\Psi = I_p/p$。主实验的幂律谱属于固定有限维机制研究；有界谱渐近验证单独进行，未混用理论适用范围。

候选参数为 $[10^{-4}, 10^2]$ 上 21 个对数等距点，再加入 $p/n$（去重后 21 或 22 点），确保各向同性时已包含精确最优单岭参数。连续单岭 oracle 在 $[10^{-6}, 10^4]$ 上先检查 101 个对数点，再精化所有检测到的局部极小值；各向同性时直接使用 $\lambda_* = p/n$。它是宽区间内的数值基准，未证明任意各向异性风险曲线全局单峰。负权重同时约束 $\mathbf{1}^\top \pi = 1$、$\|\pi\|_1 \le 3$。

**信息范围**。先验平均 oracle 只使用 $X$ 以及已知的 $\Sigma, \Psi$；实际的 Ridge-GCV、普通 GCV 平均、交叉残差平均及 LOO 平均只使用 $X, y$。广义 Bayes oracle 还知道真实各向异性先验，作为更宽方法类的参照。真实 $\beta$ 只进入独立评估

$$R_{\mathcal{D}} = 1 + (\widehat{\beta} - \beta)^\top \Sigma (\widehat{\beta} - \beta), \tag{2}$$

不参与这些算法的训练。该式将新测试点精确积分掉，因此没有额外有限测试集噪声。各配置内所有方法共享同一训练数据，差值标准误按配对重复计算；根种子为 202611041，主实验、MP 验证、确定性等价验证采用不同种子分支。图中误差线为 ±1 个 Monte Carlo 标准误，表中为均值 ±SE。配对 95% 区间为正态近似的逐项描述，没有多重比较校正。

## 3 平均家族的结构收益

表1报告给定设计后、对系数与训练噪声平均的风险。收益定义为连续单岭风险减去对应平均风险；正值表示平均更好。该目标适用于只依赖设计与生成参数的 oracle，不能用来替代数据自适应选权的实际评估。**各向同性控制**。当 $b = a$，连续单岭、包含其参数的凸平均及负权平均 oracle 均恢复

表 1: 全部主配置的条件 oracle 收益；后两列以 $10^{-3}$ 为单位

| $a$ | $p/n$ | $b-a$ | 连续单岭总风险 | 凸平均收益 ±SE | 负权平均收益 ±SE |
|---|---|---|---|---|---|
| 1.5 | 0.8 | −0.3 | 1.3057 | 2.354 ± 0.015 | 2.356 ± 0.015 |
| 1.5 | 0.8 | +0.0 | 1.2131 | 0.000 ± 0.000 | 0.000 ± 0.000 |
| 1.5 | 0.8 | +0.3 | 1.1492 | −0.343 ± 0.002 | 1.280 ± 0.007 |
| 1.5 | 1 | −0.3 | 1.3277 | 2.599 ± 0.015 | 2.601 ± 0.015 |
| 1.5 | 1 | +0.0 | 1.2224 | 0.000 ± 0.000 | 0.000 ± 0.000 |
| 1.5 | 1 | +0.3 | 1.1519 | −0.087 ± 0.001 | 1.303 ± 0.009 |
| 1.5 | 1.5 | −0.3 | 1.3620 | 2.874 ± 0.014 | 2.876 ± 0.014 |
| 1.5 | 1.5 | +0.0 | 1.2357 | 0.000 ± 0.000 | 0.000 ± 0.000 |
| 1.5 | 1.5 | +0.3 | 1.1577 | −0.358 ± 0.002 | 1.372 ± 0.009 |
| 2 | 0.8 | −0.3 | 1.1683 | 0.904 ± 0.006 | 0.904 ± 0.006 |
| 2 | 0.8 | +0.0 | 1.1175 | 0.000 ± 0.000 | 0.000 ± 0.000 |
| 2 | 0.8 | +0.3 | 1.0865 | −0.155 ± 0.001 | 0.458 ± 0.004 |
| 2 | 1 | −0.3 | 1.1723 | 0.913 ± 0.005 | 0.914 ± 0.005 |
| 2 | 1 | +0.0 | 1.1186 | 0.000 ± 0.000 | 0.000 ± 0.000 |
| 2 | 1 | +0.3 | 1.0869 | −0.036 ± 0.001 | 0.457 ± 0.004 |
| 2 | 1.5 | −0.3 | 1.1792 | 0.930 ± 0.006 | 0.930 ± 0.006 |
| 2 | 1.5 | +0.0 | 1.1211 | 0.000 ± 0.000 | 0.000 ± 0.000 |
| 2 | 1.5 | +0.3 | 1.0873 | −0.160 ± 0.001 | 0.459 ± 0.004 |

每格 100 份独立设计。均值与标准误按逐次配对风险差计算。极微小的负权额外收益仍须与优化间隙比较；例如弱谱方向下负权相对凸平均约 $10^{-6}$ 量级的差异不作实质改善结论。

同一风险，符合最优线性/Bayes 基准。当 $b < a$，凸平均在本次六个配置中有严格的正收益；当 $b > a$，有限凸候选族未胜过连续单岭，但受约束负权重获得正收益。负的凸平均收益混合了候选网格与滤波器形状限制，不能据此证明无限密网格的凸平均也存在严格劣势。这些观察是本次有限参数范围内的机制证据，不是关于任意 source condition 的“当且仅当”定理。

**排除网格混杂的补充诊断**。对相同的 1 800 个设计，将各自连续最优单岭参数再加入 oracle 候选，只重新求解凸平均；它不改变实际选权方法，也不增加独立数据量。当 $b - a = +0.3$ 时，全部 600 个增广凸平均解均回到该连续单岭顶点，收益在机器精度内为零。因此原表中这些配置的轻微负收益应归于有限网格；现有诊断支持“增广候选凸平均没有额外收益”，仍不构成关于任意正则参数连续混合的全局不可能性定理。完整逐次结果见 `anchor_diagnostic.csv`。

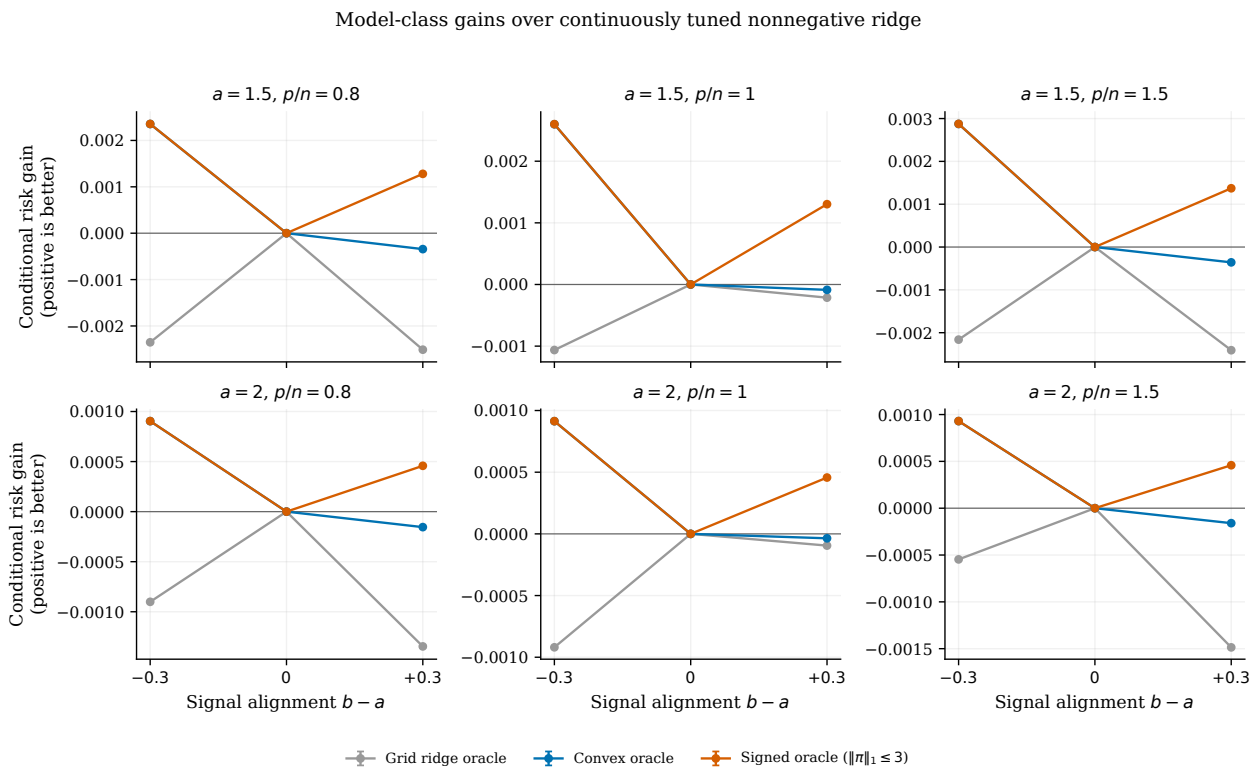



图 1: 相对连续单岭的条件风险收益。横轴为信号谱对齐差 $b-a$，灰线为离散网格单岭，蓝线为凸平均，橙线为 $\ell_1 \le 3$ 的负权平均。正值表示收益；误差线为配对均值的 ±1SE。部分误差线小于标记大小。

## 4 实际选权没有自动实现 oracle 收益

以插值附近的配置 $a = 1.5, p/n = 1, b - a = -0.3$ 为例，表2同时展示实际预测风险与训练内分数。其余配置全部保存在原始和汇总 CSV，并见图2。即使使用完全相同的最小分数，普通 GCV 与交叉残差准则也可能给出风险截然不同的实际模型。

表 2: 代表配置的总预测风险与校准；100 次配对重复

| 方法 | 总风险 ±SE | 平均分数/平均风险 | 平均 $\|\pi\|_1$ |
|---|---|---|---|
| 连续单岭 oracle | 1.3345 ± 0.0063 | – | – |
| 网格单岭 oracle | 1.3365 ± 0.0064 | – | 1.000 |
| 凸平均 oracle | 1.3319 ± 0.0063 | – | 1.000 |
| 负权平均 oracle | 1.3318 ± 0.0063 | – | 2.067 |
| 单岭 GCV | 1.3571 ± 0.0075 | 0.961 | 1.000 |
| 普通 GCV 平均 | 4.1384 ± 0.3845 | 0.303 | 1.000 |
| 交叉残差平均 | 1.4763 ± 0.0290 | 0.850 | 1.000 |
| LOO 平均 | 1.4179 ± 0.0150 | 0.894 | 1.000 |
| 负权交叉残差平均 | 1.8692 ± 0.0894 | 0.605 | 3.000 |
| 等权平均 | 1.9793 ± 0.0209 | 0.990 | 1.000 |
| 最小范数 | $3.16 \times 10^4$（样本均值） | – | – |
| 广义 Bayes oracle | 1.3308 ± 0.0063 | – | – |

oracle 的已知生成参数风险不作为训练内分数。最小范数在 $p = n$ 下的理论期望风险为无穷，样本均值仅作描述，不报告普通均值 SE。

**可实现收益与估计代价**。交叉残差与 LOO 明显缓解了普通 GCV 平均的风险膨胀，但仍未达到本次连续单岭基准；受约束负权重的实际选权反而更不稳定。该结果与“扩大函数家族就能自动提高预测表现”的推断不一致。校正矩阵能估计固定模型的风险，不意味着对许多权重取最小值后仍完全校准；本次自适应分数普遍存在向下的选择偏差。配对差值、比值的 Monte Carlo 标准误以及逐次权重均已保存，避免只比较独立组均值。相对同样仅用训练数据调参的 Ridge-GCV，本次交叉残差平均与 LOO 平均均没有出现配对 95% 区间完全低于零的配置；分别有 12 个和 11 个配置的区间完全高于零。这些是未做多重校正的 Monte Carlo 描述，不能读作普适劣势定理。

**机制核验**。全部 1 800 次重复中，普通 GCV 权重均由交叉残差最优权重按命题 3 精确转换。两种准则最小值的最大绝对差小于 $10^{-12}$，而预测风险可以相差很大。这将“指标最小化成功”和“实际预测模型好”明确区分。

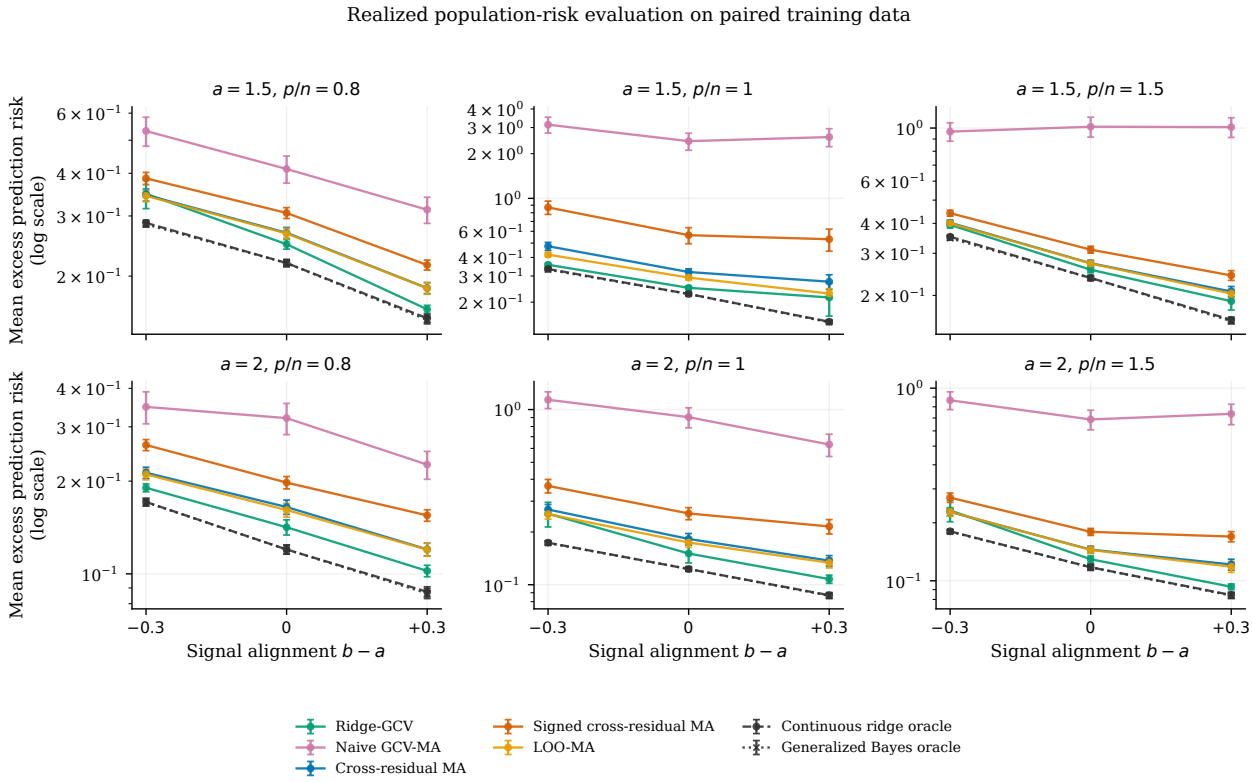



图 2: 所有主配置的实际平均超额风险，纵轴为对数尺度。所有方法共享各次训练数据，oracle 曲线使用已知生成参数。误差线为训练重复均值的 ±1SE。连续单岭与广义 Bayes 在各向同性控制中重合。

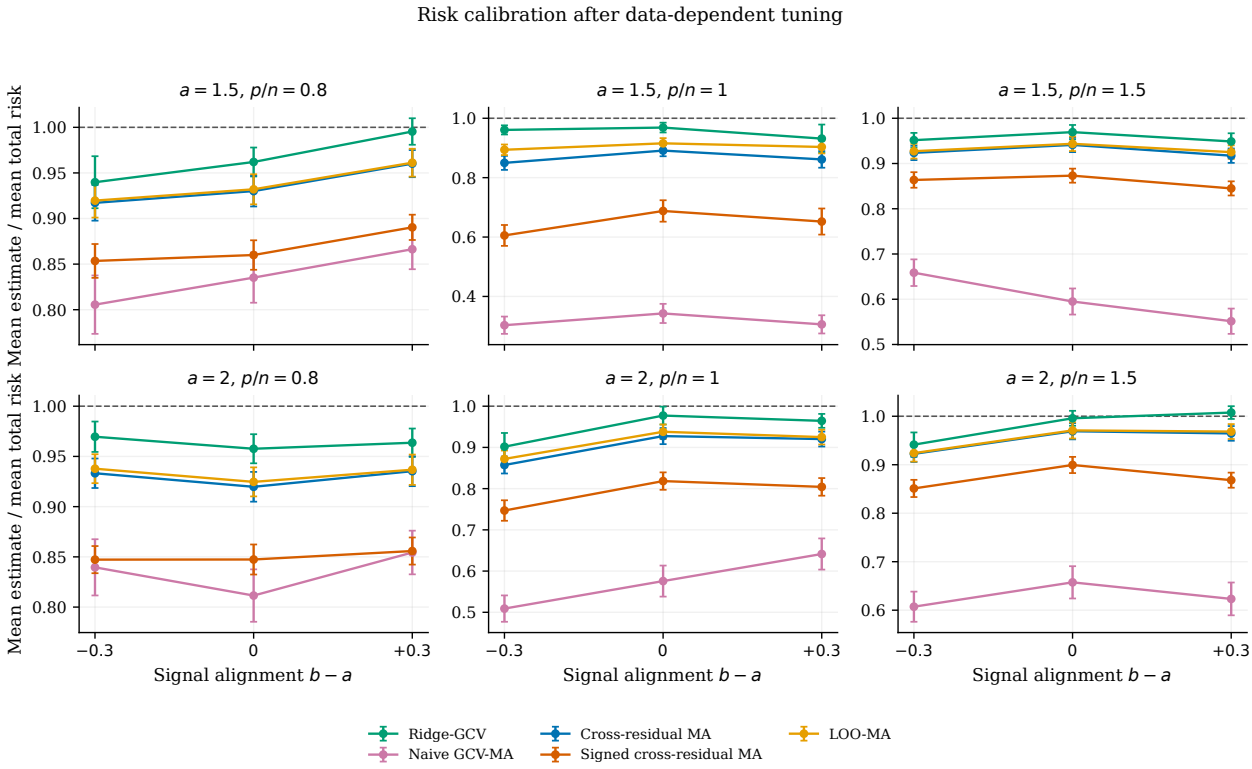



图 3: 自适应选权后的校准比，即训练内分数的重复均值除以独立评估总风险的重复均值。虚线 1 表示均值尺度校准；它不表示每份数据上都准确。误差线使用配对 delta 方法。

## 5 独立公式验证与数值审计

### 5.1 固定等权平均的 MP 反例

取单位协方差、各向同性系数、噪声方差 1、$p = n$，比较两组固定候选参数。每个规模 $n \in \{100, 300, 600\}$ 使用 100 份独立数据；两组参数共享这些数据。表3展示 $n = 600$ 的结果，与解析极限一致。此处没有优化权重，所以固定权重的 GCV 失准与数据自适应选择偏差已经被分开。这也说明

表 3: 固定等权平均：$n = 600$ 的验证结果与理论极限

| 参数对 | 实际风险 | 普通 GCV | 交叉残差 | 风险极限 | 普通 GCV 极限 |
|---|---|---|---|---|---|
| $(0.1, 1)$ | 1.7857 | 1.6799 | 1.7842 | 1.7875 | 1.6808 |
| $(0.01, 10)$ | 2.4359 | 1.7721 | 2.4293 | 2.4435 | 1.7700 |

不能仅凭单岭 GCV 的一致性就推断平均后普通 GCV 一致。

### 5.2 有界谱下的高维风险验证

另取单位谱和等比例两块谱 $\{0.5, 1.5\}$，$n \in \{100, 200, 400\}$、$p/n \in \{0.8, 1, 1.5\}$，每配置 40 次，共 720 份独立设计。比较单岭 $\lambda = 1$ 与三参数 $\lambda = (0.1, 1, 10)$、权重 $(0.2, 0.5, 0.3)$ 的固定平均。以实际样本设计的精确先验平均风险作为参照，使用总体谱方程计算确定性等价。在 $n = 400$ 的 12 个方法配置中，组均值的最大绝对相对偏差为 0.028%。

### 5.3 复现与求解精度

保存结果共含 1 800 个不同主实验种子。每个配置的首个重复均独立重跑，风险与保存值的最大绝对差为 0.00。全部方法记录的求解检查通过，最大归一化一阶间隙为 $1.91 \times 10^{-5}$，最大约束误差为 $7.99 \times 10^{-15}$。一次初始负权重求解未达到间隙阈值，已使用相同数据种子进一步求解并重新核验；没有替换训练数据。一般先验风险与直接矩阵逆计算、$p > n$ 零空间、显式删点 LOO、Bayes 基准及 GCV 换元均有独立测试。检验代码与机器可读审计记录一起交付。

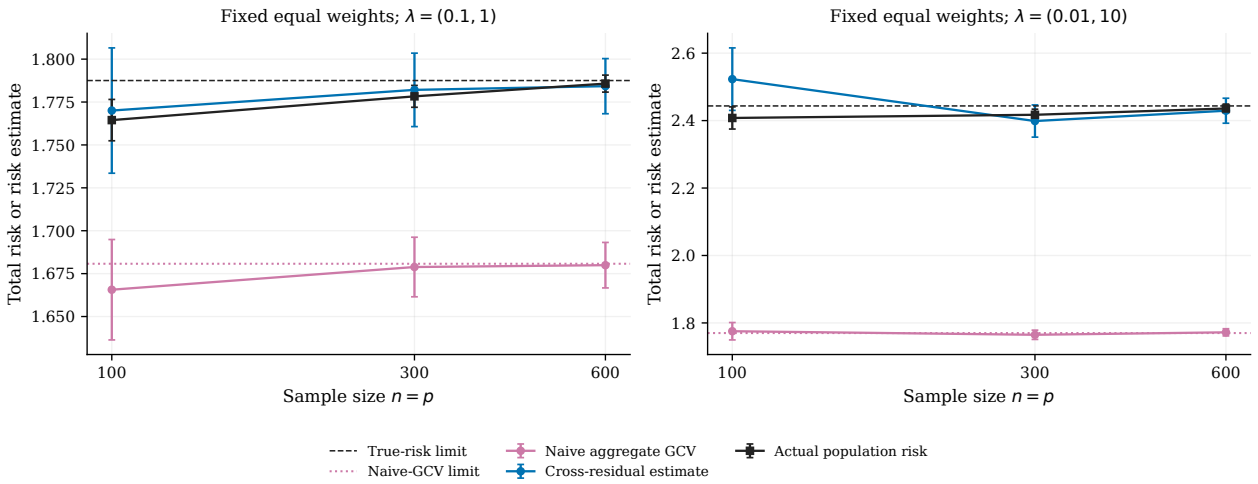



图 4: 固定权重 MP 验证：普通 GCV 与交叉残差估计随规模变化的均值及标准误，虚线为解析极限。具体曲线含义见图例；这里没有数据选权。

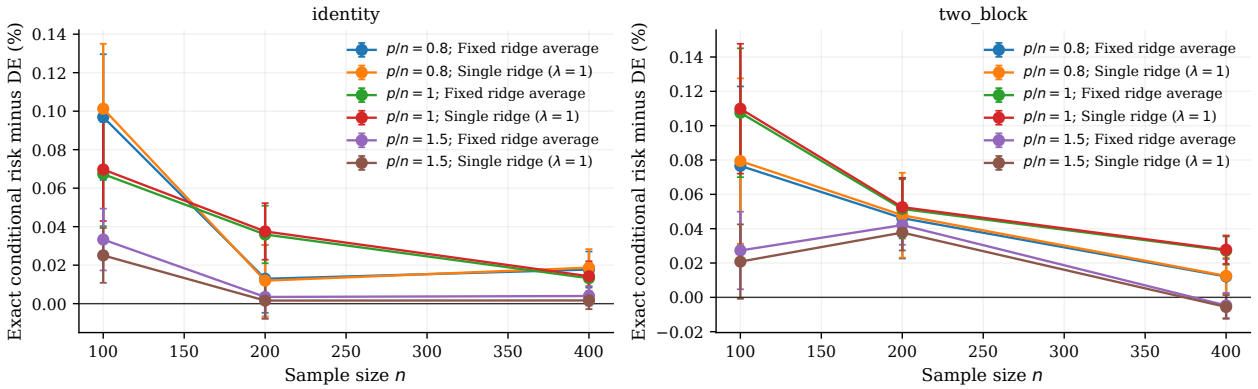



图 5: 有界总体谱下的确定性等价验证。相对误差为精确条件风险减去谱方程预测，再除以预测值。误差线为 40 次独立设计上均值的 ±1SE；单个有限样本仍存在波动。

## 6 研究边界与下一步应验收什么

本阶段完成了理论基线、source alignment 的最小模拟、普通 GCV 失准机制和独立验证。有限幂律模型中已观测到方法类收益，但幅度远小于实际权重估计损失。因此后续优先问题应是稳定选权：例如限制有效候选维数、收缩到单岭或使用独立选权数据，再检查是否能在明确场景中实现相对单岭的配对风险改善。这些是后续待检验方案，本报告没有将其当作已实现结果。

本次没有证明一般各向异性双参数风险的完整确定性等价，也没有证明候选数任意增长、正则下界趋零或无约束负权重下的统一一致性。数学附录只在明确的固定候选集、正则参数远离零及有界谱条件下陈述选权保证。所有模拟均为高斯设计、线性响应；结果尚未扩展到重尾数据或真实数据。最小范数在插值点的重尾样本另存分位数与最大值，不能用其不稳定样本均值包装风险改进。

## 7 交付清单与复现入口

- `Code/`：风险与求解模块、主实验、独立渐近验证、统计绘图、结果核查、报告生成与单元测试。
- `Results/`：逐次风险、逐候选权重、配对差值、条件 oracle 收益、校准、机制记录、种子清单与求解审计。
- `Figures/`：六组矢量 PDF 图，另附 SVG 与 PNG；最小范数的尾部分布作为补充材料。
- `Report/`：本 PDF、可编辑完整 LaTeX 源文件、数学片段和文献条件说明。
- 项目根目录的 `README.md`、`requirements.txt`、`run_all.sh` 给出完整复现顺序。

本次执行使用 Python 3.12.14、NumPy 2.5.4、SciPy 1.18.1。所需依赖均在清单中固定版本，报告由 XeLaTeX 实际编译。

## A 数学对象与两个不同的风险目标

设 $X \in \mathbb{R}^{n\times p}$ 的行为训练特征，$y = X\beta + \varepsilon$。训练噪声满足 $\mathbb{E}\varepsilon = 0$、$\mathrm{Cov}(\varepsilon) = \sigma^2 I_n$，$0 < \sigma^2 < \infty$，与系数及设计独立；新特征 $x_0$ 均值为零、协方差为 $\Sigma \succeq 0$，新噪声方差同为 $\sigma^2$，且测试点独立于训练数据。采用规范化岭损失 $\|y - Xb\|_2^2/n + \lambda\|b\|_2^2$，记

$$S = X^\top X/n, \quad Q_j = (S + \lambda_j I_p)^{-1}, \quad \widehat{\beta}_j = Q_j X^\top y/n, \qquad \lambda_j > 0. \tag{3}$$

候选数为 $K$，混合权重满足 $\mathbf{1}^\top\pi = 1$，估计器为 $\widehat{\beta}_\pi = \sum_{j=1}^K \pi_j \widehat{\beta}_j$。

**给定真实系数和训练结果的风险**。以 $\mathcal{D} = (X, y)$ 表示训练数据，定义

$$R_{\mathcal{D}}(\pi) = \mathbb{E}[(y_0 - x_0^\top\widehat{\beta}_\pi)^2 \mid X, y, \beta] = \pi^\top \mathcal{K}_{\mathcal{D}}\pi, \tag{4}$$

$$(\mathcal{K}_{\mathcal{D}})_{jk} = \sigma^2 + (\widehat{\beta}_j - \beta)^\top\Sigma(\widehat{\beta}_k - \beta). \tag{5}$$

它可以用于模拟中的精确总体评估，不需要另抽有限测试集；真实系数仅供评估，不能进入实际选权。如果以式(5)选权，则得到使用真实系数的事后 oracle。

**给定设计、对系数与训练噪声平均的风险**。另设 $\mathbb{E}\beta = 0$、$\mathrm{Cov}(\beta) = \Psi \succeq 0$，且 $\beta$ 与 $X$ 独立。对固定权重或仅依赖 $X$ 的权重，定义 $\overline{R}_X(\pi) = \mathbb{E}_{\beta,\varepsilon}[R_{\mathcal{D}}(\pi) \mid X]$。用此目标选权的 oracle 可知道生成参数 $\Sigma, \Psi, \sigma^2$，但不使用某一次真实系数或噪声的实现值。两个 oracle 的信息与目标不同，不能混为同一个基准。

**命题 1：一般先验下的精确交叉风险**。 在上述二阶矩条件下，

$$\overline{R}_X(\pi) = \sigma^2 + \pi^\top C_X\pi, \tag{6}$$

$$(C_X)_{jk} = \lambda_j\lambda_k\,\mathrm{tr}(\Sigma Q_j\Psi Q_k) + \frac{\sigma^2}{n}\,\mathrm{tr}(\Sigma S Q_j Q_k). \tag{7}$$

矩阵 $C_X$ 对称半正定；式(7)不要求 $\Sigma, \Psi, S$ 可交换。

证明。由 $Q_j S = I_p - \lambda_j Q_j$ 和权重和为一，

$$\widehat{\beta}_\pi - \beta = -\left(\sum_j \pi_j\lambda_j Q_j\right)\beta + \left(\sum_j \pi_j Q_j\right)X^\top\varepsilon/n. \tag{8}$$

两项交叉期望为零。偏差项用 $\mathbb{E}\beta\beta^\top = \Psi$ 展开，噪声项用 $\mathbb{E}\varepsilon\varepsilon^\top = \sigma^2 I_n$ 展开，即得式(7)。任意线性组合的对应二次型是两个非负方差项之和，故半正定。若 $\widehat{\pi}$ 依赖 $y$，不能把它直接代入固定权重的式(6)，并将结果认作 $\mathbb{E}[R_{\mathcal{D}}(\widehat{\pi}) \mid X]$。 □

### A.1 各向同性情形的差商与高维极限

当 $\Psi = \alpha^2 I_p/p$ 时，令 $t_p(\lambda) = p^{-1}\,\mathrm{tr}[\Sigma(S + \lambda I_p)^{-1}]$。先设候选参数两两不同。对 $j \neq k$ 定义

$$B_{jk} = \frac{t_p(\lambda_j) - t_p(\lambda_k)}{\lambda_k - \lambda_j}, \qquad V_{jk} = \frac{\lambda_k t_p(\lambda_k) - \lambda_j t_p(\lambda_j)}{\lambda_k - \lambda_j}, \tag{9}$$

$$B_{jj} = -t_p'(\lambda_j), \qquad V_{jj} = t_p(\lambda_j) + \lambda_j t_p'(\lambda_j). \tag{10}$$

那么

$$(C_X)_{jk} = \alpha^2\lambda_j\lambda_k B_{jk} + \sigma^2(p/n)V_{jk}. \tag{11}$$

其证明分别使用 $Q_jQ_k = (Q_j - Q_k)/(\lambda_k - \lambda_j)$ 和 $SQ_jQ_k = (\lambda_k Q_k - \lambda_j Q_j)/(\lambda_k - \lambda_j)$，对角取连续极限。后者说明方差交叉项包含样本协方差 $S$，不能与偏差交叉项混用。

在 Dobriban–Wager 的比例高维条件下 [1]，例如 $p/n \to \gamma \in (0, \infty)$、$X = Z\Sigma^{1/2}$、$Z$ 元素独立同分布、均值零、方差一且十二阶矩一致有界、$\|\Sigma\|_{\mathrm{op}}$ 一致有界、总体经验谱弱收敛到 $H$，对固定有限候选集、固定 $\lambda_j > 0$，可用极限 $t$ 及其导数替换式(9)–(10)中的 $t_p$。其中 $v_\lambda > 0$ 解

$$\frac{1}{v_\lambda} = \lambda + \gamma\int \frac{s}{1 + sv_\lambda}\,dH(s), \qquad t(\lambda) = \frac{1}{\gamma}\left(\frac{1}{\lambda v_\lambda} - 1\right). \tag{12}$$

这是现有随机矩阵结论与 resolvent 恒等式的组合，不作为新定理宣称。一般 $\Psi$ 的偏差项为 $\mathrm{tr}(\Sigma Q_j \Psi Q_k)$，即使 $\Psi$ 与总体 $\Sigma$ 同时对角化，也通常不与样本 $Q_j$ 交换，因而不能直接使用上述单函数差商。本项目对一般 $\Psi$ 使用式(7)的精确有限样本计算；一般 source condition 的渐近分析需要另行引用与验证 [2, 5]。

## B 连续最优单岭与平均收益的正确基准

**命题 2：各向同性二阶矩下的最优线性基准。** 给定 $X$，设 $\Psi = \alpha^2 I_p/p$，$\alpha^2, \sigma^2 > 0$，令 $V_y = (\alpha^2/p)XX^\mathsf{T} + \sigma^2 I_n$。在全部仅依赖 $X$ 的线性估计器 $Ay$ 中，

$$A_* = (\alpha^2/p)X^\mathsf{T} V_y^{-1} = (X^\mathsf{T}X + n\lambda_* I_p)^{-1}X^\mathsf{T}, \qquad \lambda_* = (p/n)\sigma^2/\alpha^2 \tag{13}$$

具有最小先验平均预测风险，而且

$$\overline{R}_X(A) - \overline{R}_X(A_*) = \mathrm{tr}\big[\Sigma(A - A_*)V_y(A - A_*)^\mathsf{T}\big] \geq 0. \tag{14}$$

证明。$\mathrm{Cov}(\beta - A_* y, y \mid X) = (\alpha^2/p)X^\mathsf{T} - A_* V_y = 0$。将 $Ay - \beta = (A_* y - \beta) + (A - A_*)y$ 的加权平方展开，交叉期望为零，余项即式(14)。若系数和噪声进一步为独立高斯，$A_* y$ 就是后验均值；平方损失的条件期望分解将该最优性扩展到全部使用同样 $X, y$ 的估计器，包括依赖 $y$ 的选权。仅有二阶矩而无高斯假设时，不宣称这个更强结论。 □

据此，须分别报告平均相对离散网格最佳单岭与连续调参最佳单岭的差距。网格未包含 $\lambda_*$ 时，正确先验下平均也可能改善离散网格的最佳值；先验各向异性后不再有上述普遍的标量岭最优保证，但这并不保证任何给定平均家族都有严格收益。例如 $S = sI_p$ 时，任意正岭的凸平均仍等价于某个单岭的标量收缩。使用真实系数的事后 oracle 不属于式(13)的信息范围。

## C 普通聚合 GCV 与交叉残差准则的精确关系

记

$$H_j = XQ_jX^\mathsf{T}/n, \quad r_j = (I_n - H_j)y, \quad d_j = 1 - \mathrm{tr}(H_j)/n, \quad \mathsf{E} = (r_1, \ldots, r_K), \quad D = \mathrm{diag}(d_1, \ldots, d_K). \tag{15}$$

正的岭参数保证 $d_j > 0$。以下以 $d = (d_1, \ldots, d_K)^\mathsf{T}$ 表示这些分量构成的向量。本文所称普通聚合 GCV 与交叉残差矩阵分别为

$$G_{\mathrm{agg}}(\pi) = \frac{\|\mathsf{E}\pi\|_2^2/n}{(d^\mathsf{T}\pi)^2}, \tag{16}$$

$$\widehat{\mathcal{K}} = D^{-1}\mathsf{E}^\mathsf{T}\mathsf{E}D^{-1}/n, \qquad G_{\mathrm{cross}}(\pi) = \pi^\mathsf{T}\widehat{\mathcal{K}}\pi. \tag{17}$$

式(17)是既有交叉风险校正框架在完整数据上的形式 [3]，不作为新方法宣称。固定权重时，删点并保持惩罚总量 $n\lambda_j$ 不变，逐候选重拟合的 LOO 残差是

$$r_i^{\mathrm{LOO,MA}} = \sum_j \pi_j \frac{r_{j,i}}{1 - H_{j,ii}}. \tag{18}$$

这是固定权重候选集合的 LOO 准则；若要计算整个自适应选权流程的外层 LOO，还需在删点后重新选权。

**命题 3：同一个二次规划可以产生不同的实际模型。** 在单纯形 $\Delta_K = \{\pi \geq 0 : \mathbf{1}^\mathsf{T}\pi = 1\}$ 上，变换

$$u_j = \frac{d_j \pi_j}{d^\mathsf{T}\pi}, \qquad \pi_j = \frac{u_j/d_j}{\sum_k u_k/d_k} \tag{19}$$

是双射，并且

$$G_{\mathrm{agg}}(\pi) = u^\mathsf{T}\widehat{\mathcal{K}}u, \qquad \min_{\pi \in \Delta_K} G_{\mathrm{agg}}(\pi) = \min_{u \in \Delta_K} G_{\mathrm{cross}}(u). \tag{20}$$

证明。 $d_j > 0$ 保证变换及其逆均将单纯形映到单纯形。由 $D^{-1}u = \pi/(d^\top\pi)$ 代入式(17)，即得等式。 □

因此，两种优化的最小分数可以完全相同，但普通 GCV 使用的实际权重为 $\pi$，交叉残差准则使用的实际权重为 $u$。对正权重分量，$\pi_j/\pi_k = (u_j/u_k)(d_k/d_j)$；较小 $d_j$ 对应更高自由度，逆变换会提高这些分量的相对比重。这给出一个无需渐近分析的机制，但并不保证每份数据上普通 GCV 的实际风险都更高。该变换一般不保持有负权重时的 $\ell_1$ 约束，也可能遇到 $d^\top\pi = 0$，故不能原样推广到负权重优化。这一命题是本项目采用的代数解释；未进行穷尽查新，不据此宣称首次发现。

### C.1 固定权重下普通 GCV 不一致的显式例子

取独立标准高斯设计，$p/n \to 1$，$\Sigma = I_p$，$\beta \sim N(0, I_p/p)$、$\varepsilon \sim N(0, I_n)$ 相互独立，固定 $\pi = (1/2, 1/2)$。令 $F$ 为比例一的 Marchenko–Pastur 分布，$u_0(s) = \sum_j \pi_j\lambda_j/(s+\lambda_j)$。预测风险与普通 GCV 分别收敛到

$$R_\infty = 1 + \int \left[u_0(s)^2 + \frac{(1-u_0(s))^2}{s}\right] dF(s), \tag{21}$$

$$G_{\mathrm{agg},\infty} = \frac{\int (s+1)u_0(s)^2\, dF(s)}{\left[\int u_0(s)\, dF(s)\right]^2}. \tag{22}$$

第一式由式(11)得到；第二式来自 $y$ 在训练样本谱基中的条件协方差 $XX^\top/p + I_n$。利用 $t(\lambda) = (\sqrt{1+4/\lambda}-1)/2$，当 $\lambda = (0.1, 1)$ 时二者分别为 1.787525057 和 1.680756692；当 $\lambda = (0.01, 10)$ 时分别为 2.443469136 和 1.769954995。这已经是在固定权重下的差异，与额外的数据选权过拟合是不同问题。

## D 受约束选权的稳定性保证与适用范围

对 $L \geq 1$，定义非空紧权重集合

$$\mathcal{W}_L = \{\pi \in \mathbb{R}^K : \mathbf{1}^\top\pi = 1,\ \|\pi\|_1 \leq L\}. \tag{23}$$

特别地 $\mathcal{W}_1 = \Delta_K$；$L > 1$ 允许负权重。

**命题 4：矩阵误差到选权误差的确定性传递。** 对任意对称矩阵 $\mathcal{K}, \widehat{\mathcal{K}}$，令 $\epsilon = \max_{j,k} |\widehat{\mathcal{K}}_{jk} - \mathcal{K}_{jk}|$。若数值解 $\widehat{\pi} \in \mathcal{W}_L$ 满足 $\widehat{\pi}^\top\widehat{\mathcal{K}}\widehat{\pi} \leq \inf_{\pi\in\mathcal{W}_L} \pi^\top\widehat{\mathcal{K}}\pi + \delta_{\mathrm{opt}}$，则

$$\sup_{\pi\in\mathcal{W}_L} |\pi^\top(\widehat{\mathcal{K}} - \mathcal{K})\pi| \leq L^2\epsilon, \tag{24}$$

$$\widehat{\pi}^\top\mathcal{K}\widehat{\pi} - \inf_{\pi\in\mathcal{W}_L} \pi^\top\mathcal{K}\pi \leq 2L^2\epsilon + \delta_{\mathrm{opt}}. \tag{25}$$

证明。逐项取绝对值得 $|\sum_{jk} \pi_j\pi_k(\widehat{\mathcal{K}} - \mathcal{K})_{jk}| \leq \epsilon(\sum_j |\pi_j|)^2 \leq L^2\epsilon$。在估计最小值和真实最小值之间加减两个估计二次型，分别用此界与优化误差，即得第二式。 □

这个界本身不说明 $\epsilon \to 0$。它说明无约束放大负权重会同步放大风险估计误差；$L = 3$ 的界常数是 $L = 1$ 时的九倍，而非免费的模型类扩张。

**推论 1：已有交叉风险界可支持的固定候选集结论。** 考虑一列高斯线性回归问题：$x_i \sim N(0, \Sigma_n)$，独立噪声为 $N(0, \sigma^2)$，$\sup_n p/n < \infty$、$\sup_n \|\Sigma_n\|_{\mathrm{op}} < \infty$；固定 $K, L$，确定性候选参数满足 $0 < \underline{\lambda} \leq \lambda_j \leq \overline{\lambda} < \infty$。令固定系数满足 $\sup_n \beta_n^\top\Sigma_n\beta_n < \infty$。则式(17)的估计矩阵对式(5)满足

$$\max_{j,k} |\widehat{\mathcal{K}}_{jk} - (\mathcal{K}_{\mathcal{D}})_{jk}| = O_{\mathbb{P}}(n^{-1/2}), \tag{26}$$

因此在数值优化误差为 $o_{\mathbb{P}}(1)$ 时，

$$R_{\mathcal{D}}(\widehat{\pi}) - \inf_{\pi\in\mathcal{W}_L} R_{\mathcal{D}}(\pi) = O_{\mathbb{P}}(L^2 n^{-1/2}) + \delta_{\mathrm{opt}} = o_{\mathbb{P}}(1). \tag{27}$$

这里的 oracle 目标是给定真实系数与训练结果的 $R_{\mathcal{D}}$，不是先验平均 $\overline{R}_X$。

*推导与引用边界。*使用 Bellec 等人交叉风险非渐近界 [3] 的 Theorem 1、式 (20)，取完整数据 $I_j = [n]$；这个逐对界允许不同的惩罚 $g_j(b) = \lambda_j \|b\|_2^2/2$。在上述条件下，它给出

$$\mathbb{E}\left[ d_j d_k \frac{|\widehat{\mathcal{K}}_{jk} - (\mathcal{K}_{\mathcal{D}})_{jk}|}{\sqrt{(\mathcal{K}_{\mathcal{D}})_{jj}(\mathcal{K}_{\mathcal{D}})_{kk}}} \right] \le \frac{C_0}{\sqrt{n}}, \tag{28}$$

其中 $C_0$ 可依赖固定的比例、谱和正则界。高斯设计给出 $\|S\|_{\mathrm{op}} = O_{\mathbb{P}}(1)$，而 $d_j \ge \underline{\lambda}/(\|S\|_{\mathrm{op}} + \underline{\lambda})$，故所有 $d_j$ 以高概率远离零。由岭线性算子的奇异值界，$\|\widehat{\beta}_j\|_2 \le \|y\|_2/(2\sqrt{n\underline{\lambda}})$；再用 $\|y\|_2^2/n = O_{\mathbb{P}}(1)$ 可得 $(\mathcal{K}_{\mathcal{D}})_{jj} = O_{\mathbb{P}}(1)$。式(28)、Markov 不等式与固定有限个指标的并界得到式(26)；最后应用命题 4。对独立随机系数，只要 $\beta^{\mathsf{T}}\Sigma_n\beta = O_{\mathbb{P}}(1)$，同样可条件化使用这个论证。

这是一条由现有逐对估计界与确定性误差传递得到的受限推论，不是对任意候选数、任意负权重或 $\lambda \to 0$ 的完整一致性定理。尤其不能把文献中随机子样本、共同惩罚的普通 GCV 不一致定理，原样当作同一设计不同 $\lambda$ 的定理。式(28)的逐对结果足以用于这里的固定候选集，但须核查所用完整数据矩阵和参数界。

## E 信号谱对齐、滤波器限制与本次结论的范围

设总体协方差的特征对为 $(\mu_i, v_i)$，$\mu_i \asymp i^{-a}$，$a > 1$。参照 source condition，令

$$\mathbb{E}\langle v_i, \beta\rangle\langle v_j, \beta\rangle = 0 \ (i \ne j), \qquad \mu_i \mathbb{E}\langle v_i, \beta\rangle^2 \asymp i^{-b}. \tag{29}$$

这里是对先验的二阶矩条件，不是某一次随机系数的逐坐标等式 [6, 2]。相应系数方差与 $i^{a-b}$ 成比例；$b = a$ 对应各向同性，$b < a$ 相对提高弱谱方向的系数方差，$b > a$ 相对强调强谱方向。比较 $b$ 时固定 $\mathrm{tr}(\Sigma\Psi)/\sigma^2$，才能排除总预测信号能量变化的影响。响应机制仍为正确线性模型，故应称为先验或正则结构变化，而非自动称线性模型误设。

在样本谱值 $s \ge 0$ 上，平均岭的拟合滤波器为

$$h_\pi(s) = \sum_j \pi_j \frac{s}{s + \lambda_j}. \tag{30}$$

凸权重下 $h'_\pi(s) > 0$、$h''_\pi(s) < 0$；允许负权重可解除这些形状限制，但固定有限 $K$ 时仍只是带固定极点的有理函数族，满足 $h_\pi(0) = 0$、$h_\pi(\infty) = 1$。它不能恢复训练设计零空间中的系数，扩大滤波器家族也不等于自动获得可实现的低风险选权。跨岭参数的外推与加权正则化已有直接研究 [4, 5]，本报告不把这些组合本身称为首次提出。

**有限维实验与渐近保证的区别。**若将截断幂律谱重新规范到 $\mathrm{tr}(\Sigma) = p$，其最大特征值会随 $p$ 增长，通常不满足上述一致有界谱假设；若不重标，经验谱又可能退化。因此本次有限维机制实验的精确风险矩阵始终有效，但它不能单独证明无限维 Scaling Law，也不能将推论 1 的一致性保证无条件外推到该幂律增维路径。本次可争取的结果是：确认一般先验的有限样本风险基线，分开测量网格收益、模型类收益和实际选权代价，并在满足明确假设的固定候选集上陈述可证明的稳定性结论。

## 参考文献

[1] Dobriban, E. and Wager, S. (2018). High-Dimensional Asymptotics of Prediction: Ridge Regression and Classification. *Annals of Statistics*, 46(1), 247–279.

[2] Richards, D., Mourtada, J. and Rosasco, L. (2021). Asymptotics of Ridge(less) Regression under General Source Condition. *AISTATS*, PMLR 130, 3889–3897.

[3] Bellec, P. C., Du, J.-H., Koriyama, T., Patil, P. and Tan, K. (2025). Corrected generalized cross-validation for finite ensembles of penalized estimators. *JRSSB*, 87(2), 289–318.

[4] Bach, F. (2021). On the Effectiveness of Richardson Extrapolation in Data Science. *SIAM Journal on Mathematics of Data Science*, 3(4), 1251–1277.

[5] Wu, D. and Xu, J. (2020). On the Optimal Weighted $\ell_2$ Regularization in Overparameterized Linear Regression. *NeurIPS* 33.

[6] Lin, L., Wu, J., Kakade, S. M., Bartlett, P. L. and Lee, J. D. (2024). Scaling Laws in Linear Regression: Compute, Parameters, and Data. *NeurIPS* 37.

[7] Zhao, S., Liao, J. and Yu, D. (2020; online 2018). Model averaging estimator in ridge regression and its large sample properties. *Statistical Papers*, 61, 1719–1739.